

**UJIAN TENGAH SEMESTER
SAINS DATA GENOM (B)**



**Dosen Pengampu:
Prof. Setia Pramana, Ph.D.**

Disusun oleh:
Shinta Chandra 2206053940

**FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
DEPARTEMEN MATEMATIKA
PROGRAM STUDI STATISTIKA
UNIVERSITAS INDONESIA
2025**

DAFTAR ISI

DAFTAR ISI.....	2
BAB I	
REVIEW ARTIKEL.....	4
1. Artikel Microarray.....	4
Judul.....	4
Tujuan Penelitian.....	4
Ringkasan.....	4
Abstrak.....	4
Metode Penelitian.....	5
Hasil dan Diskusi.....	6
Kelebihan Artikel.....	10
Kekurangan Artikel.....	11
Saran Konstruktif.....	11
Kesimpulan.....	12
2. Artikel RNA-Sequencing.....	12
Judul.....	12
Tujuan Penelitian.....	12
Ringkasan.....	12
Abstrak.....	13
Metode Penelitian.....	13
Hasil dan Diskusi.....	15
Kelebihan Artikel.....	20
Kekurangan Artikel.....	20
Saran Konstruktif.....	21
Kesimpulan.....	21
3. Perbandingan Kedua Artikel.....	21
BAB II	
PERBEDAAN TEKNOLOGI MICROARRAY DAN RNA-SEQUENCING.....	22
1. Teknologi Microarray.....	22
2. Teknologi RNA-Sequencing.....	23
3. Tabel Perbandingan Kedua Teknologi.....	23
BAB III	
GENE EXPRESSION ANALYSIS.....	24
1. Dataset Penelitian: GSE10072.....	24
2. Penjelasan Studi.....	25
Judul dalam Bahasa Indonesia.....	25
Abstrak.....	25

Ringkasan Penelitian.....	26
3. DE Gene Analysis.....	26
Visualisasi Dendogram dan box plot.....	32
Volcano Plot.....	35
Top 50 gen dari analisis Limma.....	37
4. Klasifikasi.....	37
Install Packages.....	38
Pre-processing data.....	39
Train-Test-Split Data.....	39
Random Oversampling.....	40
Modeling dan Evaluasi.....	41
Top 10 Gen berdasarkan Features Importance.....	45
Perbandingan Akurasi Model.....	45
Best Model.....	45
Evaluasi Model.....	46
Akurasi Training vs Testing.....	47
Kelebihan dan Kekurangan.....	47
Membandingkan dengan Penelitian Sebelumnya.....	50
Kesimpulan.....	51
REFERENSI.....	52
LAMPIRAN.....	53

BAB I

REVIEW ARTIKEL

1. Artikel *Microarray*

Judul

Genetic Algorithm-Based Feature Selection with Manifold Learning for Cancer Classification using Microarray Data atau dalam Bahasa Indonesia Seleksi Fitur Berbasis Algoritma Genetika dengan Pembelajaran *Manifold* untuk Klasifikasi Kanker Menggunakan Data *Microarray*

Penelitian ini ditulis oleh Wang Z., Zhou Y., Takagi T., Song J., Tian Y., dan Shibuya T. yang di *publish* pada tahun 2023 dalam BMC Bioinformatics.

Tujuan Penelitian

Mengembangkan metode klasifikasi kanker dengan menggabungkan seleksi fitur berbasis algoritma genetika dan pembelajaran manifold pada data microarray.

Ringkasan

Jurnal ini mengusulkan metode baru bernama Iso-GA untuk seleksi fitur (gen) pada klasifikasi kanker menggunakan data microarray. Iso-GA menggabungkan algoritma genetika (GA) dengan teknik manifold learning (Isomap) untuk menangani struktur non-linear data dan menggunakan indeks Davies-Bouldin (DB) sebagai fungsi evaluasi. Metode ini diuji pada delapan dataset microarray dan menunjukkan kinerja yang lebih baik dibandingkan metode benchmark lainnya, baik dalam akurasi klasifikasi maupun jumlah gen yang dipilih.

Abstrak

Data microarray telah digunakan secara luas untuk klasifikasi kanker. Karakteristik utama dari data microarray adalah “p besar dan n kecil” di mana data tersebut mengandung sejumlah kecil subjek tetapi sejumlah besar gen. Hal ini dapat mempengaruhi validitas klasifikasi. Dengan demikian, ada permintaan yang mendesak dari teknik yang mampu memilih gen yang relevan dengan klasifikasi kanker.

Penelitian ini mengusulkan metode seleksi fitur (gen) baru, Iso-GA, untuk klasifikasi kanker. Iso-GA menggabungkan algoritma pembelajaran bermacam-macam, Isomap, dalam Genetic Algorithm (GA) untuk menjelaskan struktur nonlinier laten ekspresi gen dalam data microarray. Indeks Davies-Bouldin diadopsi untuk mengevaluasi kandidat solusi dalam Isomap dan untuk menghindari masalah ketergantungan pengklasifikasi. Selain itu, kerangka kerja berbasis probabilitas diperkenalkan untuk mengurangi kemungkinan gen dipilih secara acak oleh GA. Kinerja Iso-GA dievaluasi pada delapan set data microarray benchmark kanker. Iso-GA mengungguli metode seleksi gen pembanding lainnya, yang mengarah pada akurasi klasifikasi yang baik dengan lebih sedikit gen kritis yang dipilih.

Metode Iso-GA yang diusulkan dapat secara efektif memilih lebih sedikit gen penting dari data microarray untuk mencapai kinerja klasifikasi yang kompetitif.

Kata kunci: *Cancer classification, Microarray data, Gene selection, Genetic algorithm, Manifold algorithm.*

Metode Penelitian

- Isometric feature mapping (Isomap)

Isomap dikembangkan oleh Tenenbaum et al. (2000) untuk reduksi dimensi non-linear. Berbeda dari MDS (Multidimensional Scaling) yang berbasis jarak Euclidean, Isomap menggunakan jarak geodesik (jarak terpendek sepanjang manifold).

Prosesnya:

- Bangun graf k-nearest neighbors antar data.
- Hitung jarak terpendek antar semua pasangan titik menggunakan algoritma Warshall-Floyd.
- Lakukan dekomposisi eigen (seperti MDS) untuk memproyeksikan data ke ruang berdimensi rendah.

Diperlukan dua parameter: jumlah tetangga terdekat (k) dan dimensi target (d).

- Proposed Isomap-embedded Genetic Algorithm (Iso-GA):




Fig. 4 Framework flowchart of the proposed feature selection method

- Iso-GA menggabungkan Isomap dan Genetic Algorithm (GA) untuk seleksi fitur genetik.
- Fitur dikodekan secara biner ("1" = dipilih, "0" = tidak dipilih) dengan jumlah fitur yang dipilih dibatasi (misal 30 fitur).
- Fitness function yang digunakan adalah Davies–Bouldin (DB) Index — semakin kecil nilainya, semakin jelas pemisahan antar kelas.

- Setelah beberapa iterasi GA, fitur yang sering terpilih melewati ambang probabilitas (θ) dianggap sebagai fitur penting.
- Evaluasi dilakukan menggunakan SVM (dengan kernel RBF) dan Neural Network (dengan resilient backpropagation), dalam skema 5-fold cross-validation.
- Semua eksperimen dijalankan di R menggunakan paket kofnGA dan RDRTtoolbox.

Hasil dan Diskusi

- Evaluasi Awal:

Tiga model dibandingkan: Iso-GA, MDS-GA, dan GA biasa. Evaluasi menggunakan RBF-SVM dan Rprop+NN classifier, diukur dengan Macro-AUC dan Micro-AUC.

- Hasil RBF-SVM:

Table 5 Macro-AUC means (standardized variance) of RBF-SVM classification on gene subsets selected by feature selection algorithms

Dataset	Iso-GA	MDS-GA	GA
Breast	0.857 (0.070)	0.837 (0.07)	0.825 (0.086)
CNS	0.710 (0.092)	0.796 (0.052)	0.793 (0.052)
Colon	0.874 (0.120)	0.884 (0.067)	0.826 (0.097)
Leukemia	0.962 (0.001)	0.954 (0.016)	0.939 (0.051)
Lung	0.956 (0.018)	0.965 (0.016)	0.943 (0.014)
Lymphoma	0.964 (0.004)	0.964 (0.004)	0.963 (0.003)
MLL	0.956 (0.034)	0.957 (0.034)	0.965 (0.019)
SRBCT	0.978 (0.003)	0.978 (0.003)	0.978 (0.004)

Table 6 Micro-AUC means (standardized variance) of RBF-SVM classification on gene subsets selected by feature selection algorithms

Dataset	Iso-GA	MDS-GA	GA
Breast	0.869 (0.063)	0.838 (0.092)	0.824 (0.098)
CNS	0.763 (0.086)	0.820 (0.047)	0.814 (0.054)
Colon	0.900 (0.086)	0.907 (0.076)	0.849 (0.100)
Leukemia	1.000 (0.000)	0.985 (0.032)	0.976 (0.055)
Lung	0.975 (0.007)	0.981 (0.009)	0.971 (0.005)
Lymphoma	1.000 (0.000)	0.999 (0.001)	0.998 (0.003)
MLL	0.983 (0.025)	0.980 (0.034)	0.989 (0.024)
SRBCT	0.996 (0.009)	0.997 (0.006)	0.993 (0.007)

- Iso-GA unggul di dataset: Breast, Leukemia, Lymphoma.
- MDS-GA unggul di dataset: CNS, Colon, Lung.
- Semua metode performanya mirip di dataset SRBCT.
- Uji Wilcoxon menunjukkan perbedaan tidak signifikan antar metode, namun Iso-GA punya kinerja sangat kompetitif.

- Hasil Rprop+NN:

Table 7 Macro-AUC Means (standardized variance) of Rprop+NN Classification on Gene Subsets Selected by Feature Selection Algorithms

Dataset	Iso-GA	MDS-GA	GA
Breast	0.792 (0.028)	0.781 (0.135)	0.795 (0.054)
CNS	0.644 (0.161)	0.778 (0.103)	0.680 (0.064)
Colon	0.867 (0.109)	0.789 (0.136)	0.834 (0.087)
Leukemia	0.955 (0.010)	0.944 (0.025)	0.926 (0.080)
Lung	0.959 (0.011)	0.956 (0.031)	0.949 (0.028)
Lymphoma	0.929 (0.063)	0.964 (0.004)	0.964 (0.004)
MLL	0.953 (0.036)	0.918 (0.062)	0.946 (0.046)
SRBCT	0.966 (0.020)	0.968 (0.027)	0.927 (0.087)

Table 8 Micro-AUC means (standardized variance) of Rprop+NN classification on gene subsets selected by feature selection algorithms

Dataset	Iso-GA	MDS-GA	GA
Breast	0.807 (0.019)	0.803 (0.133)	0.788 (0.058)
CNS	0.679 (0.166)	0.810 (0.051)	0.732 (0.031)
Colon	0.885 (0.102)	0.828 (0.102)	0.834 (0.087)
Leukemia	0.987 (0.018)	0.977 (0.027)	0.965 (0.075)
Lung	0.958 (0.020)	0.974 (0.024)	0.949 (0.028)
Lymphoma	0.975 (0.033)	0.997 (0.005)	0.997 (0.005)
MLL	0.973 (0.038)	0.936 (0.067)	0.971 (0.049)
SRBCT	0.991 (0.008)	0.997 (0.004)	0.993 (0.013)

- Iso-GA mengungguli metode lain di dataset: Breast, Colon, Leukemia, Lung, MLL.
- Micro-AUC Iso-GA untuk Lung dan SRBCT hampir setara dengan metode terbaik.

- Seleksi Jumlah Gen:

Table 9 Average size of selected gene subset by each method

Dataset	Proposed feature selection Framework			CER-ABC	MBEGA
	Iso-GA	MDS-GA	GA		
Breast	51.4 (4.5)	53.8 (3.3)	56.4 (3.8)	127.4 (8.3)	14.5 (4.2)
CNS	4.0 (1.4)	7.0 (1.4)	8.2 (0.8)	18.4 (2.9)	20.5 (6.9)
Colon	11.8 (2.5)	17 (2.0)	18.4 (2.7)	19.6 (4.0)	24.5 (7.0)
Leukemia	43.2 (3.3)	52.4 (3.0)	54 (4.9)	144.2 (18.3)	12.8 (4.9)
Lung	18 (8.0)	32.4 (4.9)	37.2 (5.3)	998.6 (30.02)	14.1 (7.0)
Lymphoma	48.4 (3.7)	66.6 (4.5)	71.2 (1.1)	112 (7.7)	34.3 (8)
MLL	21 (4.1)	31.8 (5.6)	38.2 (7.9)	1538.4 (56.0)	32.1 (10.6)
SRBCT	17.6 (1.9)	30.4 (1.8)	32 (2.9)	568.2 (8.3)	60.7 (11.7)

Table 10 Ranking summation

	Iso-GA	MDS-GA	GA
RBF-SVM Ranking	27.8	23.8	39.3
Rprop + NN Ranking	29	31	36
s Ranking	8	16	24
Ranking Score	64.8	70.8	99.3

$\bar{r}^{(RBF-SVM)}$: The sum of average ranking of RBF-SVM on all datasets

$\bar{r}^{(Rprop+NN)}$: The sum of average ranking of Rprop + NN on all datasets

- Iso-GA memilih jumlah gen lebih sedikit dibanding MDS-GA dan GA biasa, sambil tetap menjaga akurasi tinggi.
- Rata-rata ukuran subset gen lebih kecil dan optimal.
- Perbandingan dengan Metode Lain:

Table 11 Average Accuracy of Each Methods with Results of Wilcoxon Signed-Rank Test

Dataset	Proposed feature selection framework						CER-ABC (SVM)	CER-ABC (NN)	MBEGA
	Iso-GA (SVM)	Iso-GA (NN)	MDS-GA (SVM)	MDS-GA (NN)	GA (SVM)	GA (NN)			
Breast	0.821 ^{Ref1} (0.069)	0.735 ^{Ref2} (0.080)	0.726 ^{1**} (0.096)	0.769 ^{2ns} (0.125)	0.748 ^{1**} (0.109)	0.685 ^{2ns} (0.068)	0.811 ^{1ns} (0.058)	0.739 ^{2ns} (0.075)	0.807 ^{NA} (0.035)
CNS	0.717 ^{Ref1} (0.139)	0.633 ^{Ref2} (0.139)	0.717 ^{1ns} (0.075)	0.750 ^{2ns} (0.059)	0.733 ^{1ns} (0.037)	0.750 ^{2ns} (0.083)	0.867 ^{1ns} (0.112)	0.767 ^{2ns} (0.070)	0.722 ^{NA} (0.060)
Colon	0.826 ^{Ref1} (0.097)	0.842 ^{Ref2} (0.143)	0.858 ^{1ns} (0.081)	0.791 ^{2ns} (0.071)	0.826 ^{1ns} (0.113)	0.792 ^{2ns} (0.086)	0.844 ^{1ns} (0.142)	0.760 ^{2*} (0.089)	0.857 ^{NA} (0.055)
Leuke- mia	1.000 ^{Ref1} (0.000)	0.943 ^{Ref2} (0.060)	0.958 ^{1ns} (0.063)	0.930 ^{2ns} (0.051)	0.971 ^{1ns} (0.064)	0.971 ^{2ns} (0.064)	0.971 ^{1ns} (0.064)	0.971 ^{2ns} (0.064)	0.959 ^{NA} (0.025)
Lung	0.943 ^{Ref1} (0.014)	0.935 ^{Ref2} (0.021)	0.943 ^{1ns} (0.015)	0.951 ^{2ns} (0.013)	0.935 ^{1ns} (0.010)	0.937 ^{2ns} (0.026)	0.939 ^{1ns} (0.016)	0.921 ^{2ns} (0.006)	0.990 ^{NA} (0.009)
Lym- phoma	1.000 ^{Ref1} (0.000)	0.980 ^{Ref2} (0.027)	0.990 ^{1ns} (0.023)	0.980 ^{2ns} (0.027)	0.990 ^{1ns} (0.021)	0.971 ^{2ns} (0.043)	1.000 ^{1NA} (0.000)	0.970 ^{2ns} (0.045)	0.977 ^{NA} (0.028)
MLL	0.953 ^{Ref1} (0.048)	0.953 ^{Ref2} (0.033)	0.953 ^{1ns} (0.058)	0.888 ^{2ns} (0.104)	0.971 ^{1ns} (0.064)	0.962 ^{2ns} (0.062)	0.953 ^{1ns} (0.058)	0.925 ^{2ns} (0.043)	0.943 ^{NA} (0.033)
SRBCT	0.994 ^{Ref1} (0.013)	0.970 ^{Ref2} (0.021)	0.988 ^{1*} (0.026)	0.982 ^{2*} (0.026)	0.969 ^{1ns} (0.022)	0.988 ^{2ns} (0.017)	0.988 ^{1ns} (0.016)	0.939 ^{2**} (0.066)	0.992 ^{NA} (0.012)

**p value of Wilcoxon signed-rank test is less than the significance level of 0.05

*p value of Wilcoxon signed-rank test is less than the significance level of 0.1

ns no significant

Dibandingkan CER-ABC dan MBEGA, Iso-GA mencapai akurasi rata-rata terbaik pada 5 dari 8 dataset dan memiliki ranking performa (R score) terbaik: R = 30.5 (terendah = terbaik).

- Visualisasi:

Visualisasi menggunakan Isomap:

- Dengan semua gen: klasifikasi antar kelas sudah cukup baik.
- Dengan gen hasil Iso-GA: pemisahan antar kelas menjadi lebih jelas dan bersih, membuktikan efektivitas seleksi fitur Iso-GA.




Fig. 6 Visualization results of Leukemia (left) and Lung (right) dataset

Rangkuman hasil:

- Iso-GA menggabungkan Isomap dan GA untuk seleksi gen, mempertimbangkan struktur non-linear microarray.
 - Evaluasi fitur menggunakan DB Index, bukan akurasi classifier, sehingga metode lebih fleksibel.
 - Dengan threshold probabilitas, Iso-GA mengurangi randomness dan memilih lebih sedikit gen dengan akurasi tetap tinggi.
 - Hasil: Iso-GA mencapai akurasi terbaik di banyak dataset, dengan subset gen kecil.
 - Keterbatasan:
 - Tidak mempertimbangkan interaksi antar gen.
 - Isomap rentan untuk manifold non-konveks dan tidak menggunakan label kelas.
 - Asumsi data non-linear sulit dibuktikan.
1. Potensi ke depan: Pakai metode seperti MMD-Isomap untuk mengatasi kekurangan.

Kelebihan Artikel

1. Inovasi Metode:

- Integrasi Isomap (manifold learning) dengan GA untuk menangani struktur non-linear data microarray merupakan kontribusi utama. Pendekatan ini mengatasi keterbatasan metode linear tradisional.
- Penggunaan indeks DB sebagai pengganti akurasi klasifikasi mengurangi ketergantungan pada model klasifikasi tertentu (classifier dependency).

2. Evaluasi Komprehensif:
 - Pengujian dilakukan pada delapan dataset kanker yang beragam, mencakup klasifikasi biner dan multi-kelas.
 - Metrik evaluasi lengkap (akurasi, AUC makro/mikro) dan analisis statistik (uji Wilcoxon) memberikan validasi yang kuat.
3. Pengurangan Keacakan:
 - Framework probabilistik untuk memilih gen yang konsisten dari hasil iterasi GA mengurangi dampak keacakan dalam proses seleksi.
4. Visualisasi dan Interpretasi:
 - Visualisasi hasil reduksi dimensi dengan Isomap memperjelas pemisahan antar kelas, meningkatkan interpretabilitas hasil.

Kekurangan Artikel

1. Detail Implementasi yang Kurang:
 - Parameter GA (misalnya ukuran populasi, tingkat mutasi, atau jumlah generasi) tidak dijelaskan secara rinci, menyulitkan reproduksi eksperimen.
 - Penjelasan tentang penentuan parameter k^* (tetangga terdekat pada Isomap) dan d^* (dimensi target) masih terlalu singkat.
2. Validasi Asumsi Non-Linear:
 - Klaim bahwa data microarray memiliki struktur non-linear tidak didukung dengan analisis empiris atau referensi yang memadai.
3. Interaksi Antar Gen:
 - Metode tidak mempertimbangkan hubungan biologis atau interaksi antar gen, yang mungkin berpengaruh pada stabilitas seleksi fitur.
4. Keterbatasan Isomap:
 - Isomap memiliki kelemahan seperti ketidakstabilan topologi dan ketidakmampuan menangani non-convex manifolds. Tidak ada upaya untuk membandingkan dengan metode manifold learning lain (misalnya t-SNE atau UMAP).

Saran Konstruktif

1. Penjelasan Parameter:
 - Tambahkan detail parameter GA dan proses tuning-nya (misalnya menggunakan algoritma optimasi hyperparameter seperti grid search).
 - Jelaskan kriteria pemilihan threshold θ secara lebih mendalam, termasuk contoh perhitungan distribusi binomial.
2. Validasi Struktur Non-Linear:

- Lakukan analisis tambahan (misalnya uji geometri atau perbandingan dengan metode linear) untuk membuktikan bahwa data microarray memang memiliki struktur non-linear.
- 3. Eksplorasi Metode Manifold Lain:
 - Bandingkan Iso-GA dengan metode reduksi dimensi non-linear lainnya (misalnya t-SNE, UMAP) untuk mengevaluasi keunggulan Isomap.
- 4. Analisis Biologis:
 - Lakukan validasi biologis pada gen-gen yang terpilih (misalnya melalui pathway analysis) untuk memastikan relevansi klinisnya.
- 5. Optimasi Komputasi:
 - Analisis kompleksitas komputasi Iso-GA secara lebih rinci, terutama untuk dataset dengan dimensi sangat tinggi (misalnya >20.000 gen).

Kesimpulan

Jurnal ini memberikan kontribusi penting dalam bidang bioinformatika dengan menghadirkan metode hybrid Iso-GA yang efektif untuk seleksi fitur pada data microarray. Kinerja superior Iso-GA dalam akurasi klasifikasi dan reduksi dimensi didukung oleh evaluasi empiris yang komprehensif. Namun, kurangnya detail implementasi dan validasi asumsi non-linear menjadi titik lemah yang perlu diperbaiki. Dengan penyempurnaan pada aspek metodologi dan analisis tambahan, penelitian ini memiliki potensi besar untuk aplikasi klinis dalam diagnosis dan prognosis kanker.

2. Artikel *RNA-Sequencing*

Judul

Integrative analysis of RNA expression data unveils distinct cancer types through machine learning techniques atau dalam Bahasa Indonesia Analisis Integratif Data Ekspresi RNA Mengungkap Jenis Kanker yang Berbeda Melalui Teknik Pembelajaran Mesin.

Penelitian ini ditulis oleh Alanzi S., Alshammari N., Alruwaili M., Junaid K., Abid R., dan Ahmad F. yang di *publish* pada tahun 2024 dalam ScienceDirect Elsevier.

Tujuan Penelitian

Mengklasifikasikan berbagai jenis kanker berdasarkan data ekspresi RNA menggunakan teknik pembelajaran mesin.

Ringkasan

Jurnal ini mengusulkan kerangka kerja machine learning (ML) untuk mengklasifikasikan lima jenis kanker (BRCA, KIRC, COAD, LUAD, PRAD) menggunakan data ekspresi RNA-seq. Metode yang digunakan mencakup preprocessing data, reduksi dimensi dengan PCA, dan evaluasi 34 model ML, termasuk Neural Networks. Wide Neural

Network dilaporkan mencapai akurasi 99.995% pada data uji. Studi ini juga mencakup analisis kluster menggunakan k-means dan visualisasi hasil.

Abstrak

Kanker adalah penyakit kompleks dan heterogen, sehingga klasifikasi berbasis histopatologi kurang efektif untuk prognosis dan terapi personal. Studi ini menganalisis data RNA sequencing dari lima jenis kanker (BRCA, KIRC, COAD, LUAD, PRAD) menggunakan alur kerja machine learning yang mencakup normalisasi, seleksi fitur, reduksi dimensi, klusterisasi, dan klasifikasi. Dengan algoritma k-means, lima kluster unik terbentuk dan berkorelasi signifikan dengan tipe kanker yang diketahui. Hasil ini menunjukkan bahwa machine learning mampu mengungkap pola ekspresi gen yang kompleks dan meningkatkan pemahaman tentang heterogenitas kanker. Model Wide Neural Network yang digunakan juga menunjukkan akurasi sangat tinggi, yakni 99,834% pada data validasi dan 99,995% pada data uji.

Kata kunci: *Gene, RNA expression, cancer, Tumour, diagnosis; Machine learning; Clustering; Classification*

Metode Penelitian




Fig. 1. Process gene expression classification in various tumour types.

- Spesifikasi sistem

Penelitian ini mengevaluasi algoritma klasifikasi berbasis machine learning (ML) untuk mengklasifikasikan ekspresi gen pada berbagai jenis tumor (BRCA, KIRC, COAD, LUAD, PRAD) menggunakan data RNA-seq. Eksperimen dilakukan pada workstation Lenovo dengan spesifikasi:

- Prosesor: Intel Core i9 Generasi ke-12
- OS: Windows 11 Pro 64-bit
- Memori: 128 GB DDR4
- Penyimpanan: 4 TB SSD

- Grafis: NVIDIA RTX A4000

Alat yang digunakan: MATLAB R2023a dan Orange-v3.36.

- Pengumpulan dan Praproses Data
Data RNA-seq diambil dari UCI ML Repository (Gene Expression Cancer RNA-Seq Dataset), bagian dari RNA-Seq (HiSeq) PANCAN. Dataset ini berisi ekspresi gen pasien dengan lima jenis tumor (BRCA, KIRC, COAD, LUAD, PRAD) yang diukur menggunakan platform Illumina HiSeq.
 - Format data: Setiap sampel (801 instance) memiliki 16.383 fitur ekspresi gen dengan label "gene_XX".
 - Ukuran dataset: 801 sampel $\times$ 16.383 fitur.
- Perbandingan Model Machine Learning
Studi membandingkan 34 model ML untuk mengklasifikasikan jenis tumor berdasarkan data RNA-seq. Metode yang digunakan:
 - Validasi silang (cross-validation) 5-fold untuk menghindari overfitting.
 - Dataset bersifat multivariat dengan fitur ekspresi gen yang dinormalisasi.
- *Train-Test Split*
 - Data dibagi secara acak: 75% untuk pelatihan, 25% untuk pengujian.
 - Pada data pelatihan, digunakan K-Fold cross-validation (K=5) untuk optimasi hyperparameter.
 - Tujuan: Mengevaluasi kemampuan generalisasi model dan menentukan hyperparameter terbaik.
- Optimasi Hyperparameter
Optimasi hyperparameter krusial untuk kinerja model ML. Beberapa contoh:
 - Decision Tree: Jumlah split, kriteria split.
 - SVM: Fungsi kernel, skala kernel, box constraint.
 - Neural Network: Jumlah lapisan, ukuran lapisan, fungsi aktivasi.
 - Metode seleksi fitur: ANOVA (16.345 dari 16.383 fitur digunakan).
- Metrik Kinerja
Metrik evaluasi yang digunakan:
 - 1) Sensitivity (True Positive Rate): $TP / (TP + FN)$
 - 2) False Negative Rate (FNR): $FN / (FN + TP)$
 - 3) Precision (PPV): $TP / (TP + FP)$
 - 4) False Discovery Rate (FDR): $FP / (FP + TP)$
 - 5) AUC (Area Under Curve): Mengukur kemampuan klasifikasi model.
- Kesimpulan
Penelitian ini menggunakan data RNA-seq dari UCI ML Repository untuk membandingkan 34 model ML dalam mengklasifikasikan lima jenis kanker. Proses meliputi praproses data, pembagian dataset, optimasi hyperparameter, dan evaluasi menggunakan berbagai metrik kinerja.

Hasil dan Diskusi




Fig. 2. This visualization showcases five violin plots representing data distributions for five different clusters labelled C4, C3, C1, C2, and C5. Each plot is colour-coded for differentiation: C4 is in brown, C3 is in green, C1 is in blue, C2 is in red, and C5 is in yellow. The y-axis labelled "Silhouette" has values ranging approximately from 0.46 to 0.62. The width of each violin plot at various y-values indicates the density of data points, with wider sections symbolizing higher data density and vice versa.




Fig. 3. The provided visualization represents a horizontal bar chart that depicts the distributions of various categories, possibly referring to medical or research datasets. The chart consists of seven primary labels on the left: BRCA, COAD, KIRC, LUAD, and PRAD. Next to each primary label, there are coloured horizontal bars with labels such as C1, C2, C3, C4, and C5, each corresponding to different lengths on the x-axis. The x-axis is numerical, starting from 0 and extending up to 100, marked at intervals of 10.

- Clustering Dataset:
 - Metode clustering digunakan untuk mengkategorikan dataset berdasarkan karakteristik yang dimiliki, mengidentifikasi pola pada data RNA-seq untuk berbagai jenis kanker.
 - Hasil clustering RNA-seq menunjukkan lima cluster yang berbeda, dengan skor Silhouette yang menggambarkan koherensi dalam masing-masing cluster.
 - Tipe kanker dihubungkan dengan cluster tertentu, seperti BRCA dominan di cluster C3, COAD di C2, C4, dan C5, KIRC di C2 dan C4, LUAD di C4, dan PRAD di C1.
 - Analisis statistik (ANOVA) menunjukkan perbedaan signifikan antar tipe kanker, dengan COAD memiliki nilai rata-rata tertinggi.
- Akurasi Klasifikasi:

Table 1

Classification accuracy during training and testing.

Model Type	Accuracy % (Validation)	Total Cost (Validation)	Accuracy % (Test)	Total Cost (Test)
Fine Tree	97.496	15	99.009	2
Medium Tree	97.496	15	99.009	2
Course Tree	86.311	82	88.119	24
Linear Discriminant	99.967	0	99.978	0
Quadratic Discriminant	NaN	NaN	NaN	NaN
Efficient Logistic Regression	99.833	1	99.505	1
Gaussian Naive Bayes	89.6493	62	79.208	42
Kernel Naive Bayes	95.8263	25	91.585	17
Linear SVM	99.6663	2	99.505	1
Quadratic SVM	99.8333	1	99.505	1
Cubic SVM	99.499	3	99.505	1
Fine Gaussian SVM	80.968	114	74.257	52
Medium Gaussian SVM	36.394	381	40.594	120
Coarse SVM	36.394	381	40.594	120
Efficient Logistic Regression	99.666	2	99.505	1
Efficient Logistic SVM	99.833	1	99.856	0
Fine KNN	41.235	352	38.119	125
Medium KNN	26.711	439	25.743	150
Coarse KNN	16.861	498	17.327	167
Cosine KNN	99.666	2	99.505	1
Cubic KNN	27.713	433	26.238	149
Weighted KNN	26.210	442	25.248	151
SVM Kernel	99.833	1	99.009	2
Logistic Regression Kernel	98.998	6	98.515	3
Boosted Tree	36.394	381	40.595	120
Bagged Trees	98.165	11	98.515	3
Subspace Discriminant	99.891	0	99.900	0
Subspace KNN	99.834	1	99.163	0
RUSBoosted Tree	97.997	12	97.525	5
Narrow Neural Network	97.829	13	99.836	0
Medium Neural Network	99.812	0	99.505	1
Wide Neural Network	99.834	1	99.995	0
Bilayered Neural Network	93.489	39	95.049	10
Trilayered Neural Network	88.481	69	83.664	33

- Sebanyak 600 sampel digunakan untuk pelatihan dan validasi, sementara 201 sampel digunakan untuk pengujian.
- Setelah seleksi fitur dan reduksi dimensi (PCA), 38 fitur dihapus, dan 16.340 komponen menjelaskan 95% variansi data.
- Berbagai model ML diuji, dengan Decision Trees, Discriminant Analysis, dan Efficient Logistic Regression menunjukkan akurasi tinggi.
- Model seperti Naive Bayes, SVM, KNN, dan Neural Networks menunjukkan variabilitas lebih besar dalam akurasi.
- Kinerja dan Karakteristik Model:
 - Berbagai model menunjukkan perbedaan dalam kecepatan prediksi, waktu pelatihan, dan ukuran model.
 - Decision Trees dan Discriminant Analysis menunjukkan perbedaan signifikan dalam waktu pelatihan, sementara model Naive Bayes memiliki kecepatan yang bervariasi tergantung tipe.
 - Metode Ensemble menunjukkan kinerja konsisten dengan ukuran model yang besar dan akurasi tinggi.
- Hyperparameter dan Seleksi Fitur:
 - Hyperparameter dioptimalkan untuk meningkatkan kinerja model, dan teknik seleksi fitur mempertahankan 16.345 dari total 16.383 fitur.
 - PCA dan ANOVA digunakan untuk mereduksi dimensi dan meranking fitur, yang meningkatkan kinerja model.
- Perbandingan dan Implikasi:
 - Perdagangan antara kecepatan prediksi, waktu pelatihan, dan ukuran model terlihat jelas antar model.

- Hyperparameter memainkan peran penting dalam mengoptimalkan kinerja, dan PCA sangat penting dalam mengurangi dimensi untuk hasil yang lebih baik.

- Metrik Kinerja:



Fig. 5c. Validation confusion matrix.




Fig. 5d. Validation confusion matrix.




Fig. 5e. Validation receiver operating characteristic curve.




Fig. 5f. Validation receiver operating characteristic curve.

Table 4

Performance comparison of the anticipated classification models with benchmark studies in the identified domain.

Reference	Dataset	Algorithm	Dataset Type	Performance: Accuracy
(Hijazi and Chan, 2013)	Mixed-Lineage Leukemia	SVM Linear Gene	Gene Expression	99.89 %
(Zhang et al., 2018)	Breast Cancer	SVM-RFE-PSO	Gene Expression	81.54 %
(Alshamlan, 2018)	Binary and Multi-Class Cancer Datasets	DBQ	Gene Expression	close to 100 %
(Yuan et al., 2020)	Tumor-Educated Platelets	Evolutionary Programming-trained SVM	Gene Expression	95.93 %
(Alshareef et al., 2022)	Medical Databases (PubMed, CENTRAL, EMBASE, OASIS, and CNKI)	DNN	Gene Expression	96.21 %
(Yuan et al., 2020)	Lung Adenocarcinoma and Lung Squamous Cell Cancer	RF	Gene Expression	94.9 %
		RF	Gene Expression	93.3 %
		SVM	Gene Expression	94.7 %
		DeepCC	Gene Expression	89 %
(Gao et al., 2019)	Breast Cancer	DeepCC	Gene Expression	89 %
(Saheed, 2023)	Lymphoma	LR	Microarray	99 %
Proposed Method	Gene Expression Cancer RNA-Seq	Coarse KNN (Lowest)	Gene Expression	16.861 %
		Wide Neural Network (Highest)	Gene Expression	99.995 %

- True Positive Rates (TPR): Sebagian besar model mencapai 100% TPR untuk beberapa tipe kanker, namun model seperti Fine KNN menunjukkan kinerja lebih rendah.
- False Negative Rates (FNR): Fine KNN menunjukkan FNR tinggi pada beberapa tipe kanker, sementara model lain menunjukkan 0% FNR.
- Positive Predictive Values (PPV): Sebagian besar model menunjukkan PPV tinggi, kecuali Fine KNN yang menunjukkan PPV rendah pada beberapa kanker.
- False Discovery Rates (FDR): Fine KNN menunjukkan FDR tinggi pada beberapa kategori, sementara model lain memiliki FDR lebih rendah.
- Area Under the Curve (AUC): Fine KNN memiliki AUC terendah pada beberapa kategori, sementara model lain menunjukkan AUC yang sangat baik (mendekati 1).

Rangkuman hasil:

1. Subtipe Kanker dan Diagnosis: Memahami subtipe kanker penting untuk klasifikasi, prognosis, dan strategi pengobatan, dengan penggunaan data multi-omik dan machine learning (ML) untuk meningkatkan akurasi diagnosis.
2. Dataset RNA-Seq: Dataset RNA-Seq yang mencakup data genetik untuk lima jenis kanker menunjukkan pola yang berbeda untuk tiap jenis kanker.
3. Clustering dengan K-means: Algoritma k-means mengungkapkan pola genetik spesifik untuk setiap jenis kanker, seperti BRCA, COAD, dan lainnya.
4. Performa Model ML: Model Linear Discriminant dan Efficient Logistic Regression menunjukkan performa terbaik, sementara KNN memiliki performa yang sangat bervariasi.
5. Pentingnya Pemilihan Model: Pemilihan model ML yang tepat sangat penting untuk penelitian kanker, dan dapat meningkatkan diagnosis serta pengobatan yang lebih presisi.

6. Perbandingan Model: Model Wide Neural Network memiliki akurasi yang jauh lebih tinggi dibandingkan model KNN dan lebih unggul dari studi sebelumnya.

Kelebihan Artikel

1. Cakupan Model Luas:
 - Evaluasi 34 model ML (dari Decision Trees hingga Neural Networks) memberikan gambaran komparatif yang komprehensif.
 - Wide Neural Network menunjukkan kinerja luar biasa (akurasi ~100%), menegaskan potensi deep learning dalam bioinformatika.
2. Analisis Klaster yang Mendalam:
 - Penggunaan k-means dan visualisasi siluet score memperjelas pola ekspresi gen spesifik untuk setiap kanker.
 - Hasil klaster menunjukkan korelasi signifikan antara kelompok data dan jenis kanker (misalnya, BRCA dominan di Cluster 3).
3. Validasi Statistik:
 - ANOVA digunakan untuk memilih fitur, dan PCA (95% variance) membantu mengurangi dimensi data.
 - Metrik evaluasi lengkap (TPR, FNR, AUC) memberikan gambaran holistik tentang performa model.
4. Visualisasi Intuitif:
 - Plot violin, confusion matrix, dan ROC curve memudahkan interpretasi hasil, terutama untuk pembaca non-teknis.

Kekurangan Artikel

1. Overfitting yang Tidak Terkelola:
 - Akurasi ~100% pada data uji sangat tidak biasa untuk dataset RNA-seq yang noisy. Tidak ada langkah mitigasi overfitting (e.g., dropout, regularisasi) yang dijelaskan.
 - Kemungkinan kebocoran data atau bias dalam pembagian train-test (75-25) tanpa stratifikasi.
2. Kurangnya Interpretabilitas Biologis:
 - Tidak ada analisis gen atau pathway biologis yang berkontribusi pada klasifikasi. Neural Network menjadi "kotak hitam" tanpa insight klinis.
3. Detail Preprocessing Tidak Jelas:
 - Penanganan missing values, normalisasi, dan outlier tidak dijelaskan secara rinci.
 - Pemilihan 16.345 fitur dari 16.383 menggunakan ANOVA mungkin tidak optimal untuk data high-dimensional.
4. Validasi Eksternal Absen:

- Hanya menggunakan satu dataset (UCI). Tidak ada uji coba pada dataset independen atau validasi silang eksternal.
5. Ketidakseimbangan Kelas Tidak Diperhatikan:
- Distribusi sampel untuk setiap kanker tidak disebutkan. Akurasi tinggi bisa menyesatkan jika kelas tidak seimbang.

Saran Konstruktif

Untuk meningkatkan kualitas analisis klasifikasi gen, perlu diterapkan mitigasi overfitting seperti dropout, early stopping, regularisasi L1/L2, serta nested cross-validation untuk tuning hyperparameter. Analisis fitur penting dapat dilakukan dengan SHAP values atau Grad-CAM, diikuti pengaitan gen penting dengan pathway kanker melalui enrichment analysis. Dalam preprocessing, penting untuk menjelaskan metode normalisasi (TPM/FPKM), strategi imputasi missing values, dan mengeksplorasi reduksi dimensi non-linear seperti UMAP atau t-SNE. Validasi eksternal harus dilakukan menggunakan dataset independen (misalnya TCGA atau GEO) serta melibatkan ahli onkologi untuk konfirmasi biologis. Untuk menangani ketidakseimbangan kelas, gunakan metrik seperti F1-score atau MCC dan teknik resampling seperti SMOTE. Terakhir, penting menjaga transparansi dengan menyertakan kode lengkap, parameter, serta dataset hasil preprocessing untuk mendukung reproduksibilitas studi.

Kesimpulan

Penelitian ini memberikan kontribusi signifikan dalam bidang bioinformatika dengan mendemonstrasikan potensi ML dalam klasifikasi kanker berbasis RNA-seq. Namun, kelemahan dalam validasi, *interpretability*, dan risiko *overfitting* mengurangi dampak klinisnya. Dengan perbaikan metodologi dan kolaborasi multidisiplin, pendekatan ini dapat menjadi landasan untuk diagnostik kanker yang presisi.

3. Perbandingan Kedua Artikel

Aspek	Microarray (2023)	RNA-Sequencing (2024)
Platform	Data microarray	Data RNA-sequencing
Fokus	Seleksi fitur dan klasifikasi kanker menggunakan algoritma genetika	Klasifikasi jenis kanker menggunakan pembelajaran mesin pada data RNA-seq
Metodologi Analisis	Seleksi fitur berbasis algoritma genetika, pembelajaran manifold, klasifikasi	Seleksi fitur, reduksi dimensi, klasterisasi, dan klasifikasi dengan neural network
Hasil Utama	Peningkatan akurasi klasifikasi dan identifikasi gen-gen penting	Akurasi klasifikasi sangat tinggi dalam membedakan jenis kanker

Kelebihan	Menggabungkan metode seleksi fitur dan reduksi dimensi untuk meningkatkan akurasi	Menggunakan data RNA-seq yang lebih kaya informasi untuk klasifikasi yang lebih akurat
Kekurangan	Terbatas pada gen yang telah diketahui sebelumnya dalam microarray	Membutuhkan sumber daya komputasi besar dan teknik analisis lanjutan

BAB II

PERBEDAAN TEKNOLOGI MICROARRAY DAN RNA-SEQUENCING

1. Teknologi Microarray

Microarray adalah salah satu teknologi awal yang digunakan untuk mengukur ekspresi gen dalam jumlah besar. Cara kerjanya melibatkan pemasangan RNA sampel ke probe DNA yang sudah didesain sebelumnya pada sebuah chip. Intensitas sinyal fluoresensi yang dihasilkan menunjukkan seberapa banyak gen tertentu diekspresikan. Karena bergantung pada probe yang sudah ada, microarray hanya bisa mendeteksi gen-gen yang sudah diketahui, sehingga tidak memungkinkan untuk menemukan gen baru atau variasi transkrip yang belum dipetakan. Selain itu, teknologi ini menghasilkan data berbentuk relatif dan kurang sensitif terhadap gen dengan ekspresi yang sangat rendah atau sangat tinggi. Meski begitu, karena biayanya yang lebih terjangkau dan proses analisis yang lebih sederhana, microarray masih banyak digunakan, terutama dalam penelitian-penelitian skala besar (Wang, Gerstein, & Snyder, 2009; Marioni et al., 2008).

2. Teknologi RNA-Sequencing

Berbeda dengan microarray, RNA sequencing (RNA-Seq) menawarkan cara yang lebih fleksibel dan mendalam untuk mempelajari ekspresi gen. Teknologi ini membaca seluruh RNA yang ada dalam sampel tanpa bergantung pada probe yang sudah ditentukan sebelumnya. Karena itu, RNA-Seq tidak hanya mampu mengukur ekspresi gen-gen yang sudah dikenal, tetapi juga bisa menemukan gen baru, variasi splice, hingga berbagai jenis RNA non-coding yang sebelumnya belum teridentifikasi. Data yang dihasilkan berupa jumlah bacaan (read counts), sehingga hasil kuantifikasinya lebih akurat dan mencakup rentang ekspresi yang jauh lebih luas, termasuk untuk gen-gen dengan tingkat ekspresi yang sangat rendah. Selain itu, RNA-Seq membuka peluang untuk menganalisis variasi genetik, seperti mendeteksi mutasi dan isoform baru. Meski menawarkan banyak keunggulan, RNA-Seq membutuhkan biaya yang lebih tinggi serta keterampilan bioinformatika yang lebih kompleks dibandingkan teknologi microarray (Wang, Gerstein, & Snyder, 2009; Marioni et al., 2008).

3. Tabel Perbandingan Kedua Teknologi

Aspek	Microarray	RNA-Sequencing
Prinsip Dasar	Mengukur ekspresi gen menggunakan hibridisasi antara RNA sampel dan probe DNA yang sudah diketahui.	Menggunakan sequencing untuk membaca semua RNA yang diekspresikan dalam sampel tanpa perlu desain probe.
Jenis Data	Data berbasis intensitas fluoresensi (relatif).	Data berbasis jumlah (read counts) dari fragmen RNA (kuantitatif absolut).
Cakupan Genetik	Terbatas pada gen yang sudah diketahui (harus ada probe spesifik).	Tidak terbatas — dapat mendeteksi gen baru, splice variants, dan RNA non-coding.
Sensitivitas	Kurang sensitif terhadap ekspresi gen yang sangat rendah atau sangat tinggi.	Lebih sensitif, bisa mendeteksi ekspresi gen dalam rentang yang sangat luas.
Kemampuan Deteksi	Sulit mendeteksi mutasi baru, varian splice, atau isoform gen baru.	Dapat mendeteksi mutasi, varian splice, dan isoform baru.
Biaya dan Kompleksitas	Lebih murah dan lebih sederhana untuk dianalisis.	Lebih mahal, membutuhkan analisis bioinformatika lebih kompleks.

BAB III

GENE EXPRESSION ANALYSIS

1. Dataset Penelitian: GSE10072

Judul Data	Efek Merokok terhadap Adenokarsinoma Paru.
Ringkasan Data	Analisis berbagai stadium kanker adenokarsinoma dan jaringan paru-paru normal yang dipasangkan dengan jaringan paru-paru perokok saat ini, mantan perokok, dan tidak pernah merokok. Hingga saat ini, merokok tembakau bertanggung jawab atas lebih dari 90% kanker paru-paru. Hasil penelitian memberikan wawasan tentang dasar molekuler karsinogenesis paru yang disebabkan oleh merokok.
Organisme	<i>Homo Sapiens</i>
Jumlah sampel	107
Sumber Data	https://www.ncbi.nlm.nih.gov/sites/GDSbrowser#details
Tanggal Publish	20 Februari 2008
Platform	GPL96: [HG-U133A] Affymetrix Human Genome U133A Array
Sitasi	Landi MT, Dracheva T, Rotunno M, Figueroa JD et al. Gene expression signature of cigarette smoking and its role in lung adenocarcinoma development and survival. PLoS One 2008 Feb 20;3(2):e1651. PMID: 18297132

Data yang digunakan untuk analisis ekspresi gen adalah “GSE10072” dengan judul *Gene Expression Signature of Cigarette Smoking and Its Role in Lung Adenocarcinoma Development and Survival*. Atau singkatnya *Cigarette Smoking Effect on Lung Adenocarcinoma*.

Sampel yang dianalisis diambil dari jaringan paru-paru yang tidak terlibat dari perokok saat ini, mantan perokok, dan mereka yang tidak pernah merokok. Penelitian ini menggunakan analisis ekspresi gen menggunakan chip Affymetrix HG-U133A untuk mengevaluasi perubahan ekspresi gen yang dipicu oleh merokok. Data tersebut terdiri dari 6.321 gen (*features*) yang terukur dari 107 sampel (58 kanker paru dan 49 non-kanker), setelah melalui proses pemfilteran dan normalisasi.

2. Penjelasan Studi

Gene Expression Signature of Cigarette Smoking and Its Role in Lung Adenocarcinoma Development and Survival

Maria Teresa Landi^{1*}, Tatiana Dracheva², Melissa Rotunno¹, Jonine D. Figueroa^{1,3}, Huaitian Liu⁴, Abhijit Dasgupta¹, Felecia E. Mann², Junya Fukuoka², Megan Hames², Andrew W. Bergen¹, Sharon E. Murphy⁵, Ping Yang⁶, Angela C. Pesatori⁷, Dario Consonni⁷, Pier Alberto Bertazzi⁷, Sholom Wacholder¹, Joanna H. Shih⁴, Neil E. Caporaso^{1,9}, Jin Jen^{2,9}

¹ Division of Cancer Epidemiology and Genetics, National Cancer Institute, National Institutes of Health (NIH), Department of Health and Human Services (DHHS), Bethesda, Maryland, United States of America, ² Center for Cancer Research, National Cancer Institute, National Institutes of Health (NIH), Department of Health and Human Services (DHHS), Bethesda, Maryland, United States of America, ³ Cancer Prevention Fellowship, National Cancer Institute, National Institutes of Health (NIH), Department of Health and Human Services (DHHS), Bethesda, Maryland, United States of America, ⁴ Division of Cancer Treatment and Diagnosis, National Cancer Institute, National Institutes of Health (NIH), Department of Health and Human Services (DHHS), Bethesda, Maryland, United States of America, ⁵ Biochemistry, Molecular Biology and Biophysics, University of Minnesota Cancer Center, Minneapolis, Minnesota, United States of America, ⁶ Department of Health Science, Mayo Clinic, Rochester, Minnesota, United States of America, ⁷ Foundation OM Policlinic, University of Milan, Milan, Italy

Judul dalam Bahasa Indonesia

Tanda Ekspresi Gen dari Merokok dan Perannya dalam Perkembangan dan Kelangsungan Hidup Adenokarsinoma Paru

Abstrak

Merokok bertanggung jawab atas lebih dari 90% kasus kanker paru-paru, namun perubahan molekuler spesifik yang diinduksi oleh merokok di paru-paru, yang kemudian berkembang menjadi kanker dan memengaruhi kelangsungan hidup, masih belum sepenuhnya dipahami.

Kami melakukan analisis ekspresi gen menggunakan chip Affymetrix HG-U133A pada 135 sampel jaringan segar beku dari adenokarsinoma dan jaringan paru normal berpasangan dari perokok aktif, mantan perokok, dan individu yang tidak pernah merokok, dengan informasi status merokok yang divalidasi secara biokimia. Analisis ANOVA yang disesuaikan untuk potensi faktor perancu, prosedur pengujian berganda, Gene Set Enrichment Analysis, dan klasifikasi fungsional GO dilakukan untuk seleksi gen. Hasilnya dikonfirmasi pada jaringan adenokarsinoma dan jaringan non-kanker dari dua studi independen.

Kami mengidentifikasi tanda ekspresi gen khas akibat merokok yang mencakup gen-gen siklus sel, khususnya yang terlibat dalam pembentukan gelendong mitosis (seperti NEK2, TTK, PRC1). Ekspresi gen-gen ini dengan kuat membedakan antara perokok dan bukan perokok dalam jaringan kanker paru, serta membedakan jaringan kanker stadium awal dari jaringan non-kanker ($p < 0,001$ dan perubahan lipat $> 1,5$ pada masing-masing perbandingan), konsisten dengan peran penting jalur ini dalam karsinogenesis paru akibat merokok.

Perubahan ini tetap bertahan bahkan bertahun-tahun setelah berhenti merokok. Ekspresi NEK2 ($p < 0,001$) dan TTK ($p = 0,002$) pada jaringan paru yang tidak terlibat kanker juga berhubungan dengan peningkatan risiko kematian akibat adenokarsinoma paru sebesar 3 kali lipat pada perokok.

Penelitian kami memberikan wawasan tentang mekanisme terkait merokok dalam neoplasia paru, dan menunjukkan bahwa gen-gen mitotik yang memang diketahui terlibat dalam perkembangan kanker, diinduksi oleh merokok dan mempengaruhi kelangsungan hidup. Gen-gen ini menjadi kandidat target untuk pencegahan kimiawi (chemoprevention) dan pengobatan kanker paru pada perokok.

Ringkasan Penelitian

Penelitian tersebut mempelajari bagaimana merokok mengubah ekspresi gen di paru-paru sehingga bisa menyebabkan kanker, khususnya adenokarsinoma paru-paru. Lebih spesifiknya:

- Menganalisis ekspresi gen dari jaringan kanker dan jaringan paru-paru normal (yang dipasangkan) dari perokok aktif, mantan perokok, dan orang yang tidak pernah merokok.
- Menemukan bahwa gen-gen yang berhubungan dengan pembelahan sel (seperti NEK2, TTK, dan PRC1) lebih aktif (over-ekspresi) pada perokok dibandingkan bukan perokok, baik di jaringan kanker maupun jaringan paru normal.
- Aktivasi gen-gen ini tetap bertahan lama bahkan setelah seseorang berhenti merokok.
- Lebih lanjut, ekspresi tinggi NEK2 dan TTK di jaringan paru normal berkaitan dengan risiko kematian tiga kali lebih tinggi akibat kanker paru pada perokok.

Kesimpulannya, gen-gen ini bisa menjadi target potensial untuk pencegahan dan pengobatan kanker paru-paru pada perokok.

3. DE Gene Analysis

1) Install Packages

Pertama-tama akan dilakukan install packages untuk melakukan analisa terhadap dataset tersebut. Digunakan package ‘BioManager’ untuk meng-install library ‘GEOQuery’ dan ‘Biobase’ untuk melakukan analisa.

```
if (!requireNamespace("BiocManager", quietly = TRUE)) {  
  install.packages("BiocManager")  
}  
  
BiocManager::install(c("Biobase", "GEOquery"))  
  
library(Biobase)  
library(GEOquery)
```

2) Unduh dataset “GSE10072” menggunakan fungsi getGEO

```
dtgeo <- getGEO('GSE10072', destdir=".")  
print(dtgeo)
```

```
> print(dtgeo)
$GSE10072_series_matrix.txt.gz
ExpressionSet (storageMode: lockedEnvironment)
assayData: 22283 features, 107 samples
  element names: exprs
protocolData: none
phenoData
  sampleNames: GSM254625 GSM254626 ... GSM254731 (107
    total)
  varLabels: title geo_accession ... Stage:chl (41 total)
  varMetadata: labelDescription
featureData
  featureNames: 1007_s_at 1053_at ... AFFX-TrpnX-M_at
    (22283 total)
  fvarLabels: ID GB_ACC ... Gene Ontology Molecular
    Function (16 total)
  fvarMetadata: Column Description labelDescription
experimentData: use 'experimentData(object)'
pubMedIds: 18297132
Annotation: GPL96
```

dan didapatkan informasi dari dataset:

- Jenis Data: ExpressionSet (dalam mode penyimpanan "lockedEnvironment").
- Jumlah Fitur: 22.283 fitur (gen) yang diukur.
- Jumlah Sampel: 107 sampel.
- Nama Sampel: Terdapat 107 sampel dengan nama seperti GSM254625, GSM254626, hingga GSM254731.
- Data Eksperimen: Berisi informasi tentang artikel yang relevan dengan dataset ini (PubMed ID: 18297132).
- Platform yang Digunakan: GPL96 (Affymetrix Human Genome U133A Array), yang mengukur ekspresi gen pada manusia.

3) Transformasi format GSE menjadi **ExpressionSet**

Ubah format dataset GSE (*Gene Expression Series*) menjadi format ExpressionSet yang dilakukan agar memudahkan proses analisa secara bioinformatika lebih lanjut. Dengan ini dataset dapat dengan mudah dilakukan manipulasi, analisis statistik, serta visualisasi ekspresi gen.

```
> eset <- dtgeo
> print(eset)

ExpressionSet (storageMode: lockedEnvironment)
assayData: 22283 features, 107 samples
  element names: exprs
protocolData: none
phenoData
  sampleNames: GSM254625 GSM254626 ... GSM254731 (107
    total)
  varLabels: title geo_accession ... Stage:chl (41 total)
  varMetadata: labelDescription
featureData
  featureNames: 1007_s_at 1053_at ... AFFX-TrpnX-M_at
    (22283 total)
  fvarLabels: ID GB_ACC ... Gene Ontology Molecular
    Function (16 total)
  fvarMetadata: Column Description labelDescription
experimentData: use 'experimentData(object)'
pubMedIds: 18297132
Annotation: GPL96
```

4) *Phenotype Data*

```
phdtgeo <- pData(eset)
head(phdtgeo)

> names(phdtgeo)
[1] "title"
[4] "submission_date"
[7] "channel_count"
[10] "characteristics_ch1"
[13] "characteristics_ch1.3"
[16] "label_ch1"
[19] "hyb_protocol"
[22] "data_processing"
[25] "contact_email"
[28] "contact_department"
[31] "contact_city"
[34] "contact_country"
[37] "relation"
[40] "Gender:ch1"

"geo_accession"
"last_update_date"
"source_name_ch1"
"characteristics_ch1.1"
"molecule_ch1"
"label_protocol_ch1"
"scan_protocol"
"platform_id"
"contact_phone"
"contact_institute"
"contact_state"
"supplementary_file"
"Age at Diagnosis:ch1"
"Stage:ch1"

"status"
"type"
"organism_ch1"
"characteristics_ch1.2"
"extract_protocol_ch1"
"taxid_ch1"
"description"
"contact_name"
"contact_laboratory"
"contact_address"
"contact_zip/postal_code"
"data_row_count"
"Cigarette Smoking Status:ch1"
```

Phenotype data atau data fenotipe adalah informasi deskriptif yang menjelaskan karakteristik biologis dataset. Fungsi ini bertujuan untuk menampilkan data fenotipe dari objek *ExpressionSet*.

5) Meninjau Jumlah Gen yang akan Dianalisa

Hasil ekstraksi *Expression Set* memiliki bentuk matriks. Baris matriks merepresentasikan informasi gen sedangkan kolom matriks merepresentasikan informasi sampel yang diteliti. Untuk mengetahui jumlah gen dan sampel pada dataset, dapat digunakan fungsi `'dim()'`. Perlu diketahui juga bahwa entri pada matriks ini menyimpan informasi mengenai tingkat ekspresi gen pada sampel dan gen tersebut.

```
> expdtgeo <- exprs(eset)
> dim(expdtgeo)
[1] 22283 107
```

Terlihat bahwa dataset yang diteliti memiliki 22.283 fitur (gen) dan 107 sampel.

6) Anotasi (*Annotation*)

Anotasi dilakukan sebelum tahap analisis *limma*, langkah ini memastikan jenis platform *microarray* yang akan digunakan pada dataset. Platform menunjukkan teknologi yang digunakan untuk mengukur tingkat ekspresi gen.

```
> annotation(dtgeo)
[1] "GPL96"
```

Anotasi penting digunakan karena memungkinkan peneliti untuk menghubungkan ID probe yaitu kode unik pada setiap fitur *microarray* dengan informasi biologis seperti nama gen, memetakan jalur fungsional untuk memahami fungsi gen dalam proses biologi, dan menyelaraskan informasi *gene ontology* (GO) sebagai sistem klasifikasi fungsi gen.

```
annotation(eset) <- "hgu133plus2.db"

BiocManager::install("hgu133plus2.db", ask=FALSE)
library(hgu133plus2.db)
```

Pada dataset “GDS5430”, digunakan teknologi chip *Affymetrix Human Genome U133 Plus 2.0 Array* (hgu155plus2) yang digunakan untuk probe yang berukuran lebih dari 54.000 probe yang mendeteksi ribuan ekspresi gen manusia.

7) *Filtering* data

Proses *filtering* data merupakan tahap yang sangat penting dalam proses analisis data karena berguna dalam menghapus gen yang memiliki tingkat ekspresi gen yang rendah (tidak signifikan), menghapus probe duplikat yang dapat menyebabkan bias, menghilangkan probe tanpa anotasi gen, meningkatkan kecepatan dan efisiensi komputasi, serta menjaga stabilitas dan akurasi hasil. Berikut adalah hasil dari proses *filtering*.

```
> esetFilt = nsFilter(eset)
> print(esetFilt)
$eset
ExpressionSet (storageMode: lockedEnvironment)
assayData: 6321 features, 107 samples
  element names: exprs
protocolData: none
phenoData
  sampleNames: GSM254625 GSM254626 ... GSM254731 (107 total)
  varLabels: title geo_accession ... Stage:chl (41 total)
  varMetadata: labelDescription
featureData
  featureNames: 216705_s_at 212609_s_at ... 205241_at (6321 total)
  fvarLabels: ID GB_ACC ... Gene Ontology Molecular Function (16 total)
  fvarMetadata: Column Description labelDescription
experimentData: use 'experimentData(object)'
  pubMedIds: 18297132
Annotation: hgu133a.db

$filter.log
$filter.log$numDupsRemoved
[1] 7551

$filter.log$numLowVar
[1] 6322

$filter.log$numRemoved.ENTREZID
[1] 2079

$filter.log$feature.exclude
[1] 10
```

Berdasarkan *output* di atas, didapatkan 7551 probe yang dihapus karena terdeteksi sebagai duplikat, 6322 probe yang dihapus karena tingkat ekspresi gen rendah, 2079 probe yang tidak memiliki anotasi gen spesifik, serta 10 probe yang dihapus berdasarkan kriteria khusus lainnya.

8) Visualisasi Perbandingan Sebelum dan Sesudah Proses *Filtering*


Akan dilakukan proses membandingkan distribusi data ekspresi gen sebelum dan sesudah *filtering* dengan visualisasi histogram. Dengan visualisasi ini, peneliti dapat menilai perubahan distribusi ekspresi gen setelah *filtering*, mengidentifikasi apakah *outlier* berkurang setelah proses *filtering*, dan memastikan hasil sesudah *filtering* mendekati distribusi normal yang mempermudah analisis limma berikutnya.

```

### Extract the Expression of the Filtered Dataset ###
expdtgeoFilt <- exprs(esetFilt$eset)

### plot the original and filtered data ###
par(mfrow=c(1,2))
hist(expdtgeo, main='original')
hist(expdtgeoFilt, main="filtered")

```



```

> dim(expdtgeoFilt)
[1] 6321 107

```

Berdasarkan grafik di atas, terlihat dataset sebelum *filtering* (histogram ‘expdtgeo’) memiliki *skewness* yang condong ke sisi kanan. Hal ini menandakan bahwa adanya *outlier*. Berdasarkan grafik dataset setelah *filtering* (histogram ‘expdtgeoFit’) terlihat *skewness* yang berkurang cukup signifikan yang menunjukkan bahwa proses *filtering* dapat menstabilkan distribusi data mendekati distribusi normal. Setelah dilakukan *filtering* datanya menyusut menjadi 6321gen dan 107 sampel.

9) Differential Gene Expression (DGE) Analytics

Langkah awal dalam analisis DGE adalah melakukan pengelompokkan dan pengidentifikasian kelompok sampel dalam kategori yang akan dibandingkan. Pada dataset terlihat variasi sampel dibagi menjadi 2 variasi yaitu sampel penyakit, yaitu ‘Adenocarcinoma of the Lung’ dan sampel sehat ‘Normal Lung Tissue’. Sampel *cancer* diberikan angka ‘0’ sedangkan sampel sehat diberikan nomor ‘1’.

```

> vargrp <- phdtgeo$source_name_ch1
> table(vargrp)
vargrp
Adenocarcinoma of the Lung      Normal Lung Tissue
                    58                    49
> ### Assign Group Code ###
> group <- ifelse(vargrp=="Adenocarcinoma of the Lung", 0 , 1)
> group
[1] 0 1 0 1 0 0 0 1 0 1 1 0 0 1 0 0 1 1 0 1 0 0 1 0 1 0 1 0 1 0 0 1 0 1 0 1 0 1 0 1 0 1 0 1 0 1 0 1 0
[51] 0 1 1 0 1 0 1 0 1 0 1 0 0 0 1 0 1 0 1 0 1 0 0 0 1 0 0 1 1 0 0 1 0 1 0 1 1 1 1 0 1 0 1 0 1 0 0 0 1 0
[101] 1 0 1 0 0 1 1

```

Pemberian kode *binary* dilakukan untuk mempermudah proses analisis lanjutan seperti uji-*t* (model linear) dan pengujian beda signifikan antar kelompok. *Limma* atau *Linear Models for Microarray and RNA-seq Data* adalah metode yang dilakukan untuk menganalisis *differential gene expression* (DGE) pada *microarray* dan RNA-seq. Tujuan dari analisis *limma* adalah mengidentifikasi gen yang berbeda secara signifikan antar kelompok menggunakan model linear. Tahapan dari analisis *limma* setelah *package* terunduh adalah membuat desain matriks yang merepresentasikan perbedaan kelompok dan menerapkannya pada model *limma*.

```

BiocManager::install("limma") ## Instal Limma ##

### Limma Analysis###
library(limma)

```

```

design <- model.matrix(~vargrp)
fit <- eBayes(lmFit(expdtgeoFilt,design))
fit

```



Beberapa informasi penting dari model *limma* yang dapat diteliti lebih lanjut

- *Log Fold Change* (logFC)
Merupakan besaran dari beda ekspresi antar *group* yang sudah dibuat yaitu 'untreated' dan 'ethanol'
- *P-value*
Merupakan nilai signifikansi statistik dari beda ekspresi gen antara kedua kelompok. Nilai *p-value* yang kurang dari 0.05 menunjukkan beda ekspresi gen signifikan.
- *Adjusted P-Value*
Merupakan nilai *p-value* yang sudah dikoreksi menggunakan *false discovery rate* yang digunakan untuk mengontrol *error type one* dan menjaga validasi serta mengurangi peluang *false positive*.

10) Mengidentifikasi 50 Gen Tingkat Ekspresi ter-Signifikan

Identifikasi nilai gen dengan tingkat signifikansi paling tinggi berasal dari hasil analisis *limma* pada komponen *Log Fold Change* (logFC), *p-value*, dan *adjusted*

p-value. Berikut adalah 50 gen tingkat ekspresi dengan tingkat signifikansi tertinggi.

```
> topResult <- topTable(fit, coef=2, number=50)
> rownames(topResult)
[1] "209074_s_at" "204396_s_at" "206209_s_at" "204677_at" "210081_at" "206702_at" "209875_s_at"
[8] "204931_at" "204273_at" "219719_at" "209470_s_at" "219213_at" "32625_at" "208982_at"
[15] "219597_s_at" "203980_at" "202112_at" "213103_at" "205935_at" "204719_at" "210299_s_at"
[22] "206481_s_at" "205357_s_at" "205779_at" "204731_at" "206283_s_at" "220027_s_at" "215454_x_at"
[29] "206488_s_at" "205952_at" "204482_at" "200878_at" "203065_s_at" "206068_s_at" "203865_s_at"
[36] "202524_s_at" "213974_at" "213236_at" "219064_at" "204642_at" "200911_s_at" "209167_at"
[43] "213316_at" "218665_at" "209897_s_at" "208609_s_at" "204894_s_at" "206167_s_at" "221747_at"
[50] "220677_s_at"
```

11) Ekstrak Gen dan Ekspresi Gen Terpilih


Setelah melalui proses *Differential Gene Expression (DGE) Analytics*, gen terpilih yaitu gen dengan beda ekspresi signifikan akan diseleksi berdasarkan 3 komponen sebelumnya (*logFC*, *p-value*, *adjusted p-value*). Ekspresi gen sendiri adalah nilai kuantitatif dari aktivitas gen pada setiap sampel dataset.

```
## Extract selected gene names ##
selected <- rownames(expdtgeoFilt) %in% rownames(topResult)


## Extract the expression of the selected genes
expdtgeosel <- expdtgeoFilt[selected, ]
```

Visualisasi Dendrogram dan box plot

Grafik *heatmap* dipilih untuk menampilkan tingkat ekspresi gen dari 50 gen ter-signifikan antara dua kelompok, yaitu *cancer* dan *normal*. Setiap kolom pada *heatmap* mewakili setiap sampel dengan baris yang mewakili 50 gen paling signifikan. Warna gelap merepresentasikan tingkat ekspresi rendah pada sampel sedangkan warna terang (merah) menunjukkan gen yang memiliki tingkat ekspresi yang tinggi. Terbentuk juga garis-garis *hierarchical clustering* yang mengelompokkan gen dengan pola ekspresi serupa. Berikut adalah visualisasi *heatmap* 50 ekspresi gen paling signifikan.



Setelah memvisualisasikan 50 gen ekspresi paling signifikan dengan *heatmap*, visualisasi dapat juga dilakukan dengan *boxplot*. Akan dibuat visualisasi pada 4 gen dengan ekspresi paling signifikan dengan *boxplot*. Berikut adalah hasil visualisasi *boxplot* tersebut



Keempat gen yang dianalisis menunjukkan peningkatan tingkat ekspresi yang signifikan pada sampel 'Adenocarcinoma of the Lung' dibandingkan dengan sampel 'normal', dengan variabilitas ekspresi yang cenderung lebih tinggi pada kelompok kanker. Perbedaan ekspresi yang konsisten ini mengindikasikan potensi peran gen-gen tersebut dalam perkembangan adenokarsinoma paru-paru dan kemungkinan penggunaannya sebagai biomarker, meskipun analisis statistik lebih lanjut diperlukan untuk konfirmasi signifikansi.

12) Meninjau Nama dan Deskripsi Gen Terpilih

Variabel 'GeneSelected' menyimpan informasi penting mengenai gen yang telah dipilih dalam analisis ekspresi gen diferensial. Informasi ini mencakup simbol gen, ID Entrez, nama gen, serta anotasi *Gene Ontology* (GO). Data tersebut bermanfaat untuk analisis lebih lanjut dalam memahami implikasi biologis dari ekspresi gen yang terdeteksi.

```
#### See gene name and description ####  
  
library("annotate")  
library("hgu133plus2.db") ## Note: It depends on your chip  
  
GeneSelected <- select(hgu133plus2.db, rownames(topResult),  
                      c("SYMBOL", "ENTREZID", "GENENAME"))
```

Berikut merupakan informasi yang terkandung pada *output* 'GeneSelected'

- ProbeID (*Probe Identifier*)
Kode unik yang mengidentifikasi oligonukleotida spesifik (*probe*) pada platform *microarray* yang dimana setiap *probe* mewakili urutan gen atau transkrip yang diukur dalam eksperimen.
- Simbol (*Gene Symbol*)
Berupa singkatan gen yang ditetapkan oleh HGNC (HUGO Gene Nomenclature Committee) untuk manusia dan MGI (Mouse Genome Informatics) untuk tikus. Fungsinya dari simbol tersebut adalah memberi identitas gen yang mudah dibaca dan dikenali.
- EntrezID (Entrez Gene ID)
Merupakan identifikasi numerik unik oleh NCBI pada setiap gen. Hal ini menjadi referensi universal yang terhubung dengan database genomik lain selain NCBI sehingga dapat dilakukan *retrieval* otomatis.

Variabel 'GeneSelected' dapat dilihat lebih lanjut pada [Lampiran 5](#).

13) Mengambil Informasi Anotasi *Genetik Ontology Gen* untuk Gen Terpilih

```
### Gene Ontology for the top genes###
library(GO.db)

##

GOselected <- select(GO.db, GeneSelected$GO, c("TERM", "GOID"))
head(GOselected)
```

```
ids <- rownames(topResult)


GeneSelected <- select(hgu133plus2.db, ids, c("SYMBOL", "ENTREZID",
"GENENAME", "GO"))

## Lakukan jika belum meng install GO.db
BiocManager::install("GO.db")
```

```
> head(GOselected)
      GOID      TERM
1 GO:0001558 regulation of cell growth
2 GO:0001725 stress fiber
3 GO:0001725 stress fiber
4 GO:0003674 molecular_function
5 GO:0003779 actin binding
6 GO:0005515 protein binding
```

Kode di atas digunakan untuk mengambil informasi anotasi *Gene Ontology* (GO) yang berkaitan dengan gen terpilih setelah dilakukannya analisis ekspresi gen.

Volcano Plot



Volcano plot ini merupakan visualisasi hasil analisis differential gene expression (ekspresi gen diferensial) menggunakan metode Limma, yang membandingkan dua kelompok sampel (kemungkinan 'lung cancer' dan 'normal' seperti pada visualisasi sebelumnya). Sumbu horizontal (sumbu-x) menunjukkan Log2 Fold Change (logaritma basis 2 dari perubahan lipatan), yang mengukur seberapa besar perbedaan ekspresi gen antara kedua kelompok. Nilai positif menunjukkan gen yang lebih tinggi ekspresinya pada kelompok pertama (misalnya, 'lung cancer'), sedangkan nilai negatif menunjukkan

gen yang lebih tinggi ekspresinya pada kelompok kedua ('normal'). Sumbu vertikal (sumbu-y) menampilkan $-\log_{10}$ dari nilai p yang telah disesuaikan (Adjusted P-value). Semakin tinggi nilai pada sumbu-y, semakin signifikan perbedaan ekspresi gen tersebut secara statistik.

Setiap titik pada plot merepresentasikan satu gen. Warna titik mengindikasikan signifikansi dan besarnya perubahan ekspresi:

- Abu-abu (NS): Gen-gen ini tidak dianggap signifikan secara diferensial. Mereka mungkin memiliki perubahan ekspresi yang kecil atau nilai p yang tinggi (tidak signifikan secara statistik), atau keduanya.
- Biru (P-value): Gen-gen ini memiliki nilai p yang signifikan (di bawah batas tertentu, biasanya 0.05) tetapi perubahan ekspresinya (Log2 Fold Change) tidak melebihi batas yang ditetapkan (dalam kasus ini, $|\text{Log2FC}| > 1$). Ini berarti perbedaannya mungkin signifikan secara statistik tetapi tidak terlalu besar secara biologis.
- Merah (P-value & Log2 FC): Gen-gen ini memenuhi kedua kriteria signifikansi: nilai p yang signifikan (Adjusted P-value < 0.05) dan perubahan ekspresi yang besar ($|\text{Log2FC}| > 1$). Gen-gen inilah yang dianggap paling menarik karena menunjukkan perbedaan ekspresi yang signifikan secara statistik dan substansial secara biologis antara kedua kelompok.

Garis putus-putus vertikal pada nilai Log2 Fold Change -1 dan 1 menunjukkan batas perubahan ekspresi yang dianggap signifikan (fold change 2 kali lipat ke atas atau ke bawah). Garis putus-putus horizontal menunjukkan batas signifikansi statistik (Adjusted P-value 0.05, sehingga $-\log_{10}(0.05) \approx 1.3$).

Kesimpulan dari Volcano Plot:

Plot ini secara visual menyoroti sejumlah besar gen (titik-titik merah) yang secara signifikan mengalami up-regulated (lebih tinggi ekspresinya di sisi kanan plot) atau down-regulated (lebih rendah ekspresinya di sisi kiri plot) pada salah satu kelompok dibandingkan dengan kelompok lainnya. Gen-gen yang terletak jauh di atas garis horizontal dan jauh dari garis vertikal (terutama yang berwarna merah) adalah kandidat gen yang paling kuat untuk menjadi penyebab atau konsekuensi dari perbedaan antara kedua kelompok yang dibandingkan. Beberapa gen spesifik yang menarik (berlabel) dapat diidentifikasi berdasarkan posisinya pada plot, menunjukkan besarnya perubahan ekspresi dan tingkat signifikansinya. Misalnya, gen-gen di kuadran kanan atas sangat menarik karena secara signifikan lebih tinggi ekspresinya pada kelompok pertama dengan perubahan lipatan yang besar.

Top 50 gen dari analisis Limma

```
> rownames(topResult)
[1] "209074_s_at" "204396_s_at" "206209_s_at" "204677_at" "210081_at"
[6] "206702_at" "209875_s_at" "204931_at" "204273_at" "219719_at"
[11] "209470_s_at" "219213_at" "32625_at" "208982_at" "219597_s_at"
[16] "203980_at" "202112_at" "213103_at" "205935_at" "204719_at"
[21] "210299_s_at" "206481_s_at" "205357_s_at" "205779_at" "204731_at"
[26] "206283_s_at" "220027_s_at" "215454_x_at" "206488_s_at" "205952_at"
[31] "204482_at" "200878_at" "203065_s_at" "206068_s_at" "203865_s_at"
[36] "202524_s_at" "213974_at" "213236_at" "219064_at" "204642_at"
[41] "200911_s_at" "209167_at" "213316_at" "218665_at" "209897_s_at"
[46] "208609_s_at" "204894_s_at" "206167_s_at" "221747_at" "220677_s_at"
```

4. Klasifikasi

Data hasil filtering yang terdiri dari 107 sampel dan 6321 gen disimpan ke dalam bentuk csv untuk dilakukan klasifikasi terhadap jaringan kanker paru (0) dan jaringan normal (1).

```
#simpan grup label dan sampel dalam format csv
data_filter_trans <- t(expdtgeoFilt)
write.csv(data_filter_trans, "data_filter1.csv", row.names = TRUE)

#file nyimpan label grup yang benar
group_df <- data.frame(SampleID = colnames(expdtgeoFilt),
                      group = group)
write.csv(group_df, "label_grup_sampel1.csv", row.names = FALSE)
```

Selanjutnya untuk mempermudah analisis akan digunakan *tools* Google Colab untuk metode klasifikasi. Berikut cuplikan datanya:

	216705_s_at	212609_s_at	207079_s_at	207895_at	209027_s_at	202382_s_at	203256_at	209451_at	221847_at	208650_s_at	...	205014_at
Sample_ID												
GSM254625	5649742776	7717797262	7769613435	5880062629	8691076011	904353647	1194136629	7745176301	8363151697	8966154431	...	7955149973
GSM254626	5264447382	8146483655	7700904795	6244164141	8845278456	8286780624	7816035209	7740150033	7826218789	589536552	...	7926222996
GSM254627	5902318052	595697127	8354186314	5898566762	8713816156	9167969097	9037214111	6426137934	7940070503	6830542058	...	8043326562
GSM254628	5592102054	8285237763	7218578857	6038320173	8795327644	8150441998	8436326432	7547010445	8034463727	6070808868	...	8272854276
GSM254629	5029953363	61268955	7444881947	5974968505	8376672169	9033735203	8097473202	7888022104	762598328	4950248718	...	81648201
...	...	...	...	...	...	...	...	...	...	...	...	...
GSM254727	6150833845	8214507541	6873141756	6362249397	8669259061	8274340974	7419090764	7065682084	813339263	5878842688	...	8031916287
GSM254728	6067940347	6988097742	7160686755	5831498987	8013220036	897138665	1050586938	6747178977	7886554197	8059454843	...	7786031266
GSM254729	6031751192	705056918	7039323571	6388817473	8003769133	8780686405	1075651247	7135588642	7169198089	7016765447	...	8290000357
GSM254730	558503298	7982533222	6731609701	6491550568	8196433855	8473043954	8286536759	7200125373	7373020772	497486493	...	7803388771
GSM254731	5561375767	7649548694	6520426602	6157744195	8181942207	8199328858	8093104483	6433599396	7597034652	5482977533	...	800899292

107 rows × 6321 columns

dan berikut cuplikan labelnya:

SampleID	group
GSM254625	0
GSM254626	1
GSM254627	0
GSM254628	1
GSM254629	0
...	...
GSM254727	1
GSM254728	0
GSM254729	0
GSM254730	1
GSM254731	1

107 rows × 1 columns

0 = sakit cancer, 1 = normal

Install Packages

Sebelum membangun model klasifikasi, pertama-tama akan dilakukan instalasi *library* yang diperlukan oleh masing-masing model, sehingga proses pemodelan dapat dilakukan menggunakan Python.

```

1 import pandas as pd
2 import numpy as np
3 #visualisasi
4 import seaborn as sns
5 import matplotlib.pyplot as plt
6 #preprocessing data
7 from sklearn.preprocessing import StandardScaler
8 from imblearn.over_sampling import RandomOverSampler
9 from sklearn.model_selection import train_test_split
10 from sklearn.preprocessing import StandardScaler
11 #modeling
12 from sklearn.neighbors import KNeighborsClassifier
13 from sklearn.metrics import classification_report, accuracy_score, confusion_matrix
14 from sklearn.linear_model import LogisticRegression
15 from sklearn.naive_bayes import GaussianNB
16 from sklearn.ensemble import RandomForestClassifier
17 from sklearn.svm import SVC
18 from sklearn.metrics import confusion_matrix, classification_report
19 from sklearn.tree import DecisionTreeClassifier

```

Pre-processing data

Setelah melalui tahap pengecekan missing value ternyata data sudah lengkap dan bersih.

```
1 data_filter.isna().sum()
0
216705_s_at 0
212609_s_at 0
207079_s_at 0
207895_s_at 0
209027_s_at 0
...
201131_s_at 0
214697_s_at 0
214198_s_at 0
222201_s_at 0
205241_s_at 0
...
1 label.isna().sum()
0
group 0
dtype: int64
6321 rows x 1 columns
```

Setelah itu data label dan hasil filter digabung menjadi seperti pada cuplikan di bawah ini:

```
1 combined_df
209451_at  221847_at  208650_s_at  ...  205332_at  209067_s_at  203301_s_at  201594_s_at  201131_s_at  214697_s_at  214198_s_at  222201_s_at  205241_at  group
7745176301  8363151697  8966154431  ...  5900982246  9711226866  9374281308  1110402669  1213494143  7603544301  9138496859  7819584604  9402392782  0
7740150033  7826218789  589536552  ...  6082449721  9457121491  9505744923  1027770314  1047344842  6254675467  8700101424  7843210877  8208421418  1
6426137934  7940070503  6830542058  ...  6846837242  9273027126  9181866287  1022272526  101593216  676122624  7543772166  7780359794  838168905  0
7547010445  8034463727  6070808868  ...  6090352295  100312709  923026019  1038058717  1012719207  6421011584  8663684722  7894457911  8655012646  1
7888022104  762598328  4950248718  ...  6309835438  9499613251  9386101897  9863795716  1214071338  6659352558  8767591379  7379967257  8969463457  0
...
7065682084  813339263  5878842688  ...  6451467051  9929428828  9259843873  107913817  9828466725  5640954083  8445343327  729364399  906851274  1
6747178977  7886554197  8059454843  ...  6549291353  9191456561  8700979592  1008547702  1138383133  5974441018  8825884722  7524664711  8639780297  0
7135588642  7169198089  7016765447  ...  696178089  880779365  8811694631  9689799464  1147774306  64254656  7787797991  744763633  9281876619  0
7200125373  7373020772  497486493  ...  6690854273  9022691821  920743236  9930910552  9397545056  5600214268  8445175377  7388078412  8879991912  1
6433599396  7597034652  5482977533  ...  6523083023  9735432025  8883681519  1003064714  9813143501  599935733  8294777386  7446399056  8947541335  1
```

Train-Test-Split Data

Untuk melakukan pelatihan model, kedua dataset (data ekspresi gen dan label grup) akan dibaca dan disimpan menjadi sebuah variabel, sehingga akan memudahkan proses pemanggilan dataset ketika akan dilakukan proses pelatihan dan pengujian model. Setelah itu, dilakukan normalisasi terhadap data pada gen yang telah difilter. Normalisasi bertujuan untuk menyamakan skala antar fitur, sehingga nilai ekspresi gen berada dalam rentang yang seragam, dimana hal ini dapat meningkatkan kinerja machine learning, terutama pada algoritma yang sensitif terhadap skala data.


Selanjutnya, dataset akan dibagi menjadi dua bagian, yaitu 70% sebagai data training dan 30% sebagai data testing.

```
X = data_filter  
y = label['group']
```

```
1 #normalisasi  
2 scaler = StandardScaler()  
3 X_scaled = scaler.fit_transform(X)
```


```
1 X_train, X_test, y_train, y_test = train_test_split(  
2 | | X_scaled, y, test_size=0.3, random_state=42)
```

Random Oversampling



Setelah di cek menggunakan bantuan visualisasi *pie chart* ternyata pembagian group pada data training tidak seimbang. Oleh karena itu, perlu dilakukan penyeimbangan kelas menggunakan teknik ROS atau Random Oversampling.

Distribution of Resampled Target Variable



Original target distribution:

```
group
0    41
1    33
Name: count, dtype: int64
```

Resampled target distribution:

```
group
0    46
1    46
Name: count, dtype: int64
```

Modeling dan Evaluasi

Setelah dataset dibagi menjadi dua bagian, data akan digunakan melatih dan menguji model. Data training digunakan untuk melatih model agar model mampu melakukan prediksi terhadap kelas (klasifikasi), sedangkan data testing digunakan untuk mengevaluasi kinerja model dalam melakukan klasifikasi pada data yang belum pernah dilihat sebelumnya. Kinerja model akan dinilai menggunakan confusion matrix, evaluation metrics, dan ROC-AUC curve.

Berikut adalah confusion matrix dan classification report untuk masing-masing algoritma:

- K-Nearest Neighbors (KNN)

```
Confusion Matrix
[[14  3]
 [ 0 16]]
```

```
Classification Report:
              precision    recall  f1-score   support

     0           1.00       0.82      0.90         17
     1           0.84       1.00      0.91         16

 accuracy              0.91         33
 macro avg           0.92      0.91      0.91         33
 weighted avg       0.92      0.91      0.91         33
```

Akurasi KNN: 0.9090909090909091

Confusion matrix

TN = Sebanyak 14 sampel kanker paru berhasil diprediksi sesuai kelasnya

FN = Sebanyak 0 sampel normal yang salah diprediksi sebagai kanker paru

TP = Sebanyak 16 sampel normal berhasil diprediksi sesuai kelasnya

FP = Sebanyak 3 sampel kanker paru yang salah diprediksi sebagai normal

Berdasarkan kinerja model KNN, diperoleh bahwa model dapat memprediksi klasifikasi kelas dengan tingkat akurasi sebesar 91%. Hal ini mengindikasikan bahwa model ini sangat baik untuk data ini.

b. Regresi Logistik

```
Confusion Matrix
[[17  0]
 [ 0 16]]
```

```
Classification Report:
              precision    recall  f1-score   support

     0           1.00       1.00      1.00         17
     1           1.00       1.00      1.00         16

 accuracy              1.00         33
 macro avg           1.00      1.00      1.00         33
 weighted avg       1.00      1.00      1.00         33
```

Akurasi Regresi Logistik: 1.0

Confusion matrix

TN = Sebanyak 17 sampel kanker paru berhasil diprediksi sesuai kelasnya

FN = Tidak ada sampel yang salah diprediksi sebagai kanker paru

TP = Sebanyak 16 sampel normal berhasil diprediksi sesuai kelasnya

FP = Tidak ada sampel yang salah diprediksi sebagai normal

Berdasarkan kinerja model regresi logistik, diperoleh bahwa model dapat memprediksi klasifikasi kelas dengan tingkat akurasi sebesar 100%.

c. Naive Bayesian

```
Confusion Matrix
[[17  0]
 [ 5 11]]
```

```
Classification Report:
              precision    recall  f1-score   support

     0       0.77      1.00      0.87        17
     1       1.00      0.69      0.81        16

 accuracy          0.85        33
 macro avg         0.89      0.84      0.84        33
 weighted avg      0.88      0.85      0.84        33
```

Akurasi Naive Bayes: 0.8484848484848485

Confusion matrix

TN = Sebanyak 17 sampel kanker paru berhasil diprediksi sesuai kelasnya

FN = Sebanyak 5 sampel yang salah diprediksi sebagai kanker paru

TP = Sebanyak 11 sampel normal berhasil diprediksi sesuai kelasnya

FP = Tidak ada sampel yang salah diprediksi sebagai normal

Berdasarkan kinerja model naive bayesian, diperoleh bahwa model dapat memprediksi klasifikasi kelas dengan tingkat akurasi sebesar 85%.

d. Decision Tree

```
Confusion Matrix
[[17  0]
 [ 3 13]]
```

```
Classification Report:
              precision    recall  f1-score   support

     0       0.85      1.00      0.92        17
     1       1.00      0.81      0.90        16

 accuracy          0.91        33
 macro avg         0.93      0.91      0.91        33
 weighted avg      0.92      0.91      0.91        33
```

Akurasi Decision Tree: 0.9090909090909091

Confusion matrix

TN = Sebanyak 17 sampel kanker paru berhasil diprediksi sesuai kelasnya

FN = Sebanyak 3 sampel yang salah diprediksi sebagai kanker paru

TP = Sebanyak 13 sampel normal berhasil diprediksi sesuai kelasnya

FP = Tidak ada sampel yang salah diprediksi sebagai normal

Berdasarkan kinerja model naive bayesian, diperoleh bahwa model dapat memprediksi klasifikasi kelas dengan tingkat akurasi sebesar 91%.

e. Random Forest

Confusion Matrix

```
[[17  0]
 [ 0 16]]
```

Classification Report:

	precision	recall	f1-score	support
0	1.00	1.00	1.00	17
1	1.00	1.00	1.00	16
accuracy			1.00	33
macro avg	1.00	1.00	1.00	33
weighted avg	1.00	1.00	1.00	33

Akurasi Random Forest: 1.0

Confusion matrix

TN = Sebanyak 17 sampel kanker paru berhasil diprediksi sesuai kelasnya

FN = Tidak ada sampel yang salah diprediksi sebagai kanker paru

TP = Sebanyak 16 sampel normal berhasil diprediksi sesuai kelasnya

FP = Tidak ada sampel yang salah diprediksi sebagai normal

Berdasarkan kinerja model regresi logistik, diperoleh bahwa model dapat memprediksi klasifikasi kelas dengan tingkat akurasi sebesar 100%.

f. Support Vector Machine (SVM)

Confusion Matrix

```
[[14  3]
 [ 0 16]]
```

Classification Report:

	precision	recall	f1-score	support
0	1.00	0.82	0.90	17
1	0.84	1.00	0.91	16
accuracy			0.91	33
macro avg	0.92	0.91	0.91	33
weighted avg	0.92	0.91	0.91	33

Akurasi SVM: 1.0

Confusion matrix


TN = Sebanyak 14 sampel kanker paru berhasil diprediksi sesuai kelasnya

FN = Tidak ada sampel yang salah diprediksi sebagai kanker paru


TP = Sebanyak 16 sampel normal berhasil diprediksi sesuai kelasnya

FP = Sebanyak 3 sampel yang salah diprediksi sebagai normal

Top 10 Gen berdasarkan Features Importance



Perbandingan Akurasi Model



Model regresi logistik, SVM, dan Random forest mungkin tidak cocok untuk data ini karena terlalu sempurna dan mengindikasikan adanya *overfitting* yang sangat kuat. Sementara itu, model KNN, Naive Bayes, dan Decision Tree masih masuk akal dan cocok untuk data penelitian ini karena akurasi model yang tinggi namun tidak *perfect* seperti ketiga metode yang disebut di awal.


Best Model

Didapatkan model terbaik untuk dataset 'GSE10072' adalah model KNN dan Naive Bayes yang memiliki akurasi sama, yaitu 91%.

Evaluasi Model

Setelah meninjau confusion matrix dan classification report untuk masing-masing algoritma, kinerja model akan dinilai menggunakan perbandingan akurasi model dan kurva ROC-AUC yang masing-masing menggambarkan tingkat ketepatan dan kemampuan model dalam membedakan antar kelas.

Kurva ROC dan AUC




Kurva ROC ini membandingkan performa beberapa model klasifikasi (KNN, Logistic Regression, Naive Bayes, Decision Tree, Random Forest, SVM) dalam membedakan dua kelas (kemungkinan 'lung cancer' dan 'normal'). Sumbu vertikal adalah True Positive Rate (sensitivitas), dan sumbu horizontal adalah False Positive Rate (1 - spesifisitas). Kurva yang lebih mendekati sudut kiri atas menunjukkan performa yang lebih baik.

Nilai AUC (Area Under the Curve) di legenda memberikan ukuran ringkas performa setiap model. AUC 1.00 menunjukkan klasifikasi sempurna, sedangkan AUC 0.5 (garis putus-putus) setara dengan tebakan acak.

Dari kurva ini, terlihat bahwa Logistic Regression dan Random Forest menunjukkan performa terbaik dengan AUC 1.00, diikuti oleh KNN (AUC = 0.97) dan Naive Bayes (AUC = 0.94) yang juga sangat baik. Decision Tree (AUC = 0.91) memiliki performa yang sedikit lebih rendah dibandingkan model lainnya. Secara keseluruhan, sebagian

besar model mampu membedakan kedua kelas dengan baik, jauh di atas tingkat tebakan acak.

Akurasi Training vs Testing



Grafik batang ini membandingkan akurasi model klasifikasi pada data training (biru) dan data testing (merah). Akurasi yang tinggi menunjukkan performa model yang baik dalam memprediksi kelas dengan benar.

Terlihat bahwa Logistic Regression, SVM, dan Random Forest mencapai akurasi sempurna (1.00) pada data training dan testing. KNN dan Decision Tree juga menunjukkan akurasi yang tinggi, meskipun sedikit lebih rendah pada data testing dibandingkan training. Naive Bayes memiliki akurasi yang baik pada data training, namun sedikit menurun pada data testing.

Secara keseluruhan, sebagian besar model menunjukkan performa yang sangat baik dalam mengklasifikasikan data, dengan sedikit indikasi overfitting (performa jauh lebih baik pada training daripada testing) pada beberapa model seperti KNN dan Decision Tree. Logistic Regression, SVM, dan Random Forest tampak paling robust karena mempertahankan akurasi sempurna pada kedua set data.

Kelebihan dan Kekurangan

a. K-Nearest Neighbors (KNN)

Kelebihan:

- Implementasi Sederhana: Konsep dan implementasi KNN relatif mudah dipahami.
- Non-Parametrik: Tidak membuat asumsi yang kuat tentang distribusi data.
- Adaptif: Dapat beradaptasi dengan batas keputusan yang kompleks.
- Performa Baik: Menghasilkan akurasi yang tinggi (91%) pada dataset ini.

Kekurangan:

- Sensitif terhadap Skala Fitur: Kinerja dapat menurun jika fitur tidak diskalakan dengan baik.
- Mahal Secara Komputasi (pada data besar): Waktu prediksi bisa lama karena perlu menghitung jarak ke semua titik data pelatihan.
- Pemilihan K yang Optimal: Kinerja sangat bergantung pada pemilihan nilai K yang tepat.
- Sensitif terhadap Data yang Tidak Seimbang: Dapat bias terhadap kelas mayoritas.
- Adanya Kesalahan Prediksi: Masih terdapat false negative (0) dan false positive (3).

b. Regresi Logistik

Kelebihan:

- Interpretasi Baik: Koefisien model dapat diinterpretasikan untuk memahami hubungan antara fitur dan probabilitas kelas.
- Efisien Secara Komputasi: Relatif cepat dalam pelatihan dan prediksi.
- Performa Sangat Baik: Mencapai akurasi 100% pada dataset ini.
- Tidak Ada Kesalahan Prediksi: Tidak ada false negative maupun false positive.

Kekurangan:

- Asumsi Linearitas: Mengasumsikan hubungan linear antara fitur dan log-odds dari kelas.
- Kurang Fleksibel untuk Batas Keputusan Non-Linear: Mungkin tidak bekerja dengan baik jika batas keputusan antar kelas sangat kompleks.
- Potensi Overfitting: Akurasi 100% perlu diwaspadai terhadap kemungkinan overfitting.

c. Naive Bayesian

Kelebihan:

- Implementasi Sederhana: Mudah diimplementasikan.
- Efisien Secara Komputasi: Cepat dalam pelatihan dan prediksi.
- Performa Baik pada Data dengan Banyak Fitur: Bekerja baik meskipun dengan jumlah fitur yang besar.
- Tidak Ada False Positive: Tidak ada sampel normal yang salah diprediksi sebagai kanker.

Kekurangan:

- Asumsi Independensi Fitur (Naive): Mengasumsikan semua fitur independen satu sama lain, yang seringkali tidak realistis dalam data sebenarnya.
- Performa Kurang Optimal: Akurasi (85%) lebih rendah dibandingkan model lain.

- Adanya False Negative: Terdapat 5 sampel normal yang salah diprediksi sebagai kanker.

d. Decision Tree

Kelebihan:

- Interpretasi Mudah: Struktur pohon keputusan mudah dipahami dan divisualisasikan.
- Non-Parametrik: Tidak membuat asumsi tentang distribusi data.
- Dapat Menangani Fitur Kategorikal dan Numerik: Tidak memerlukan pra-pemrosesan khusus untuk tipe fitur yang berbeda.
- Performa Baik: Menghasilkan akurasi yang tinggi (91%).
- Tidak Ada False Positive: Tidak ada sampel normal yang salah diprediksi sebagai kanker.

Kekurangan:

- Rentan terhadap Overfitting: Pohon yang terlalu dalam dapat sangat cocok dengan data pelatihan tetapi gagal melakukan generalisasi dengan baik.
- Tidak Stabil: Perubahan kecil pada data pelatihan dapat menghasilkan pohon yang sangat berbeda.
- Kesalahan Prediksi: Terdapat 3 false negative.

e. Random Forest

Kelebihan:

- Akurasi Tinggi: Mencapai akurasi 100% pada dataset ini.
- Mengurangi Overfitting: Ensemble dari banyak pohon keputusan cenderung lebih robust dan mengurangi risiko overfitting dibandingkan satu pohon tunggal.
- Dapat Menangani Fitur Penting: Dapat memberikan informasi tentang pentingnya fitur.
- Robust terhadap Outlier: Kurang sensitif terhadap outlier dibandingkan beberapa model lain.
- Tidak Ada Kesalahan Prediksi: Tidak ada false negative maupun false positive.

Kekurangan:

- Interpretasi Lebih Sulit: Ensemble dari banyak pohon lebih sulit diinterpretasikan dibandingkan satu pohon keputusan.
- Lebih Mahal Secara Komputasi: Pelatihan bisa lebih lama karena melibatkan pembuatan banyak pohon.
- Potensi Overfitting: Meskipun lebih kecil kemungkinannya, overfitting masih bisa terjadi jika parameter tidak diatur dengan baik.

f. Support Vector Machine (SVM)

Kelebihan:

- Efektif pada Data Dimensi Tinggi: Bekerja baik pada dataset dengan banyak fitur.
- Robust terhadap Outlier: Berusaha memaksimalkan margin antara kelas, sehingga kurang terpengaruh oleh outlier yang berada jauh dari batas keputusan.
- Dapat Memodelkan Batas Keputusan Non-Linear: Dengan penggunaan kernel trick.
- Performa Baik: Menghasilkan akurasi yang tinggi (91%).
- Tidak Ada False Negative: Tidak ada sampel normal yang salah diprediksi sebagai kanker.

Kekurangan:

- Kurang Interpretatif: Model "kotak hitam" yang sulit diinterpretasikan koefisiennya.
- Pemilihan Kernel dan Parameter: Kinerja sangat bergantung pada pemilihan kernel dan parameter yang tepat.
- Mahal Secara Komputasi (pada data besar): Pelatihan bisa mahal untuk dataset yang sangat besar.
- Sensitif terhadap Skala Fitur: Perlu penskalaan fitur yang baik.
- Adanya False Positive: Terdapat 3 sampel kanker yang salah diprediksi sebagai normal.

Membandingkan dengan Penelitian Sebelumnya

Dalam penelitian ini, saya mengkaji performa beberapa model klasifikasi pada dataset ekspresi gen GSE10072, yang terdiri dari sampel kanker paru-paru dan normal. Hasil yang saya peroleh menunjukkan bahwa model Logistic Regression, SVM, dan Random Forest mampu mencapai akurasi sebesar 100%, sementara model KNN dan Decision Tree masing-masing memperoleh akurasi sebesar 91%, dan model Naive Bayes mencapai akurasi 85%.

Jika dibandingkan dengan penelitian sebelumnya, seperti yang dilakukan oleh Chen et al. (2007) dan Shedden et al. (2008), akurasi yang diperoleh dalam studi saya relatif lebih tinggi. Dalam penelitian terdahulu, Logistic Regression dan SVM umumnya menghasilkan akurasi pada kisaran 85–95%, sedangkan Random Forest mencapai akurasi sekitar 90–95%. Untuk model Naive Bayes, akurasi yang dilaporkan sebelumnya berkisar antara 80–87%, dan model KNN serta Decision Tree cenderung menghasilkan akurasi di bawah 90% apabila tidak dilakukan pemilihan fitur yang optimal.

Perbandingan ini menunjukkan bahwa hasil klasifikasi saya, terutama pada model Logistic Regression, SVM, dan Random Forest, memberikan performa yang lebih unggul dibandingkan dengan hasil penelitian terdahulu. Kemungkinan perbedaan ini disebabkan oleh penggunaan teknik preprocessing data dan feature selection yang lebih selektif dalam penelitian saya. Namun demikian, saya menyadari bahwa akurasi yang sangat

tinggi ini juga perlu dievaluasi lebih lanjut untuk memastikan bahwa model tidak mengalami overfitting. Oleh karena itu, diperlukan validasi tambahan, seperti penggunaan metode cross-validation atau data uji eksternal, guna mengonfirmasi kemampuan generalisasi model yang dikembangkan.

Kesimpulan

Dari hasil evaluasi berbagai metode klasifikasi, Regresi Logistik dan Random Forest menunjukkan performa terbaik dengan akurasi sempurna (100%) dalam membedakan sampel kanker paru dan normal, tanpa adanya kesalahan prediksi. KNN dan Decision Tree juga memberikan hasil yang sangat baik dengan akurasi 91%. Sementara itu, Naive Bayes memiliki akurasi yang sedikit lebih rendah (85%). SVM juga menunjukkan performa yang sangat baik dengan akurasi 91%, namun dengan pola kesalahan prediksi yang berbeda dari KNN. Secara keseluruhan, Regresi Logistik dan Random Forest menjadi pilihan model terbaik untuk tugas klasifikasi ini berdasarkan akurasi yang diperoleh.

REFERENSI

- [1] Wang, Z., Zhou, Y., Takagi, T., Liu, H., & Chen, L. (2023). Genetic algorithm-based feature selection with manifold learning for cancer classification using microarray data. *BMC Bioinformatics*, 24(1), 152. <https://doi.org/10.1186/s12859-023-05267-3>
- [2] Alanzi S., Alshammari N., Alruwaili M., et al.. (2024). Integrative analysis of RNA expression data unveils distinct cancer types through machine learning techniques. *Saudi Journal of Biological Sciences*. <https://doi.org/10.1016/j.sjbs.2023.103918>
- [3] Wang, Z., Gerstein, M., & Snyder, M. (2009). RNA-Seq: a revolutionary tool for transcriptomics. *Nature Reviews Genetics*, 10(1), 57–63. <https://doi.org/10.1038/nrg2484>
- [4] Marioni, J. C., Mason, C. E., Mane, S. M., Stephens, M., & Gilad, Y. (2008). RNA-seq: an assessment of technical reproducibility and comparison with gene expression arrays. *Genome research*, 18(9), 1509–1517. <https://doi.org/10.1101/gr.079558.108>
- [5] Landi, M. T., Dracheva, T., Rotunno, M., Figueroa, J. D., Liu, H., Dasgupta, A., Mann, F. E., Fukuoka, J., Hames, M., Bergen, A. W., Murphy, S. E., Yang, P., Pesatori, A. C., Consonni, D., Bertazzi, P. A., Wacholder, S., Shih, J. H., Caporaso, N. E., & Jen, J. (2008). Gene expression signature of cigarette smoking and its role in lung adenocarcinoma development and survival. *PloS one*, 3(2), e1651. <https://doi.org/10.1371/journal.pone.0001651>
- [6] Shedden, K., Taylor, J. M. G., Enkemann, S. A., Tsao, M. S., Yeatman, T. J., Gerald, W. L., ... & Beer, D. G. (2008). Gene expression-based survival prediction in lung adenocarcinoma: a multi-site, blinded validation study. *Nature Medicine*, 14(8), 822–827. <https://doi.org/10.1038/nm.1790>
- [7] Chen, H. Y., Yu, S. L., Chen, C. H., Chang, G. C., Chen, C. Y., Yuan, A., ... & Yang, P. C. (2007). A five-gene signature and clinical outcome in non-small-cell lung cancer. *New England Journal of Medicine*, 356(1), 11–20. <https://www.nejm.org/doi/full/10.1056/NEJMoa060096>

LAMPIRAN

Kode R:

https://drive.google.com/file/d/1EHaQgyKiu1Jvr7IEs9YSb5Ix6uwHMdbd/view?usp=drive_link

Kode Python:

https://drive.google.com/file/d/1rFIMHkRKgC4gJnfpiJLhWWMkNfYQHLT_/view?usp=drive_link